北京大学
PEKING UNIVERSITY

人脑皮层空间转录组分析：层相关表达与跨切片预测

姓名 陈辰　　院系 第一临床医学院

摘　要

空间转录组可用于研究基因表达与脑皮层结构的关系。本文复分析公开的人脑背外侧前额叶皮层 Visium 数据，使用同一供体的两张相邻切片，共读取 7312 个捕获点、33,538 个基因，经质量控制和标签筛选后纳入 7234 个点。分析包括稀疏矩阵读取、图像配准、归一化、训练集内特征选择与降维、层间差异、空间自相关、聚类及解剖层预测。MBP 等白质相关基因呈明显的空间聚集；邻域平滑后，聚类 ARI 从 0.174 升至 0.222。以 151673 为开发切片、151674 为留出切片，逻辑回归的宏平均 F1 为 0.536、宏平均 AUROC 为 0.896，随机森林的宏平均 F1 为 0.468。白质较易识别，错误主要集中于相邻皮层及参考边界附近。七类中六类的跨片表达对比以同名层相关最高，开发片选出的 21 个候选基因在留出片均保持正方向。加入八维图像特征后，宏 F1 为 0.518，未见预测改善。这些结果说明，同供体相邻切片间存在可重复的层相关表达，但精细分层仍有困难。报告附组织图、统计与评估图、交互网页及核心代码；结论限于本次双切片复分析。

关键词：空间转录组；脑皮层；Python；空间自相关；跨切片预测

Abstract

Spatial transcriptomics measures gene expression within tissue architecture. We reanalysed two adjacent human dorsolateral prefrontal cortex Visium sections from one donor. Of 7,312 input spots, 7,234 passed quality and label filters. Analyses included image alignment, preprocessing, layer contrasts, spatial autocorrelation, clustering and layer prediction. Neighbour smoothing increased the adjusted Rand index from 0.174 to 0.222. Logistic regression trained on section 151673 achieved a macro-F1 of 0.536 and a macro-AUROC of 0.896 on section 151674. White matter was more readily identified than adjacent cortical layers, with errors concentrated near reference boundaries. Six of seven regions showed their highest cross-section expression correlation with the corresponding region; all 21 training-selected candidates retained positive contrasts in the second section. Adding eight image features yielded a macro-F1 of 0.518 and did not improve prediction. Histology, statistical figures, an interactive website and core code accompany the analysis. The results characterize within-donor spatial reproducibility; reference labels incorporate expression evidence, and performance in new donors remains untested.

Keywords: spatial transcriptomics; cortex; Python; spatial autocorrelation; cross-section prediction

目录

1 第一部分：个人主页与课程目标 1
1.1 个人主页网址 1
1.2 从课程大纲到具体分析任务 1
1.3 研究问题与分析边界 1

2 第二部分：空间转录组的研究背景与方法综述 2
2.1 组织位置与表达解释 2
2.2 DLPFC 数据与研究设计 3
2.3 从表达聚类到空间建模 3
2.4 整合单细胞信息的价值与边界 3
2.5 从高通量测序到原位成像：技术路线的比较 4
2.6 组织图谱、疾病研究与多模态整合 4
2.7 空间变异基因与统计尺度 4
2.8 组织图与定量比较 5

3 数据来源、读取与图像配准 5
3.1 数据构成与来源追踪 5
3.2 稀疏矩阵与条码连接 5
3.3 坐标缩放与切片方向 6

4 预处理：从质量控制到训练集内降维 6
4.1 质量指标与预先固定的规则 6
4.2 归一化、对数变换与高变特征 7
4.3 可复现配置与泄漏防范 8

5 统计分析：层相关表达与空间自相关 8
5.1 预先指定的标志基因面板 8
5.2 层间检验、效应量与多重比较 9
5.3 Moran's I 与空间邻域图 10
5.4 以 MBP 为例的调整模型 11

6 降维与空间区域识别 12
6.1 低维表达结构 12
6.2 表达聚类与邻域平滑聚类的直接对照 12

7 预测模型建立与评估 13
7.1 任务定义、模型与固定参数 13
7.2 验证设计 13
7.3 整体性能与不确定性 13
7.4 各层分类表现 14
7.5 ROC、PR 与类别不平衡 15
7.6 校准、预测熵与空间错误定位 15
7.7 基因系数回投 16

8 扩展分析一：从局部形态到跨切片表达一致性 17
8.1 多尺度组织学观察及其作用 17
8.2 跨切片层表达一致性 18
8.3 候选基因发现与方向复核 19

9 扩展分析二：连续梯度、邻域结构与聚类稳定性 20
9.1 参考分层引导的几何深度曲线 20
9.2 参考层邻域接触与置换基准 21
9.3 空间自相关的多尺度敏感性 22
9.4 聚类对随机初始化的敏感性 23

10 扩展分析三：错误结构、模型分歧与图像消融 24
10.1 灰白质分类与精细分层 24
10.2 置信度排序与距离边界的错误梯度 24
10.3 模型分歧及配对比较 26
10.4 图像特征消融实验 26

11 项目展示网页与可复现交付 28
11.1 交互切片查看器 28
11.2 文件组织与复现实验 28

12 讨论 29
12.1 空间结构与预测表现 29
12.2 跨片一致性与图像消融 29
12.3 主要局限 30
12.4 后续研究 30

13 结论 31

参考文献 32

致谢 35

A 核心代码 36
A.1 HDF5 读取、坐标连接与参考标签 36
A.2 归一化与只在训练集拟合的预处理器 36
A.3 邻接图、Moran's I 与置换检验 37
A.4 模型参数与评估函数 37
A.5 训练/测试分离与实际执行循环 37
A.6 组织图像特征与配对空间块比较 38

B 数据与文献核验清单 38

1 第一部分：个人主页与课程目标

1.1 个人主页网址

本次制作的个人主页为：

https://ccipad123.github.io/

主页包含 Home、Publications、Projects 与 Experience 四个页面，介绍个人背景、研究方向、已发表论文、科研项目、获奖、教学与志愿服务经历及联系方式。网站采用静态 HTML、CSS 和 JavaScript 实现，由 GitHub Pages 托管，适配电脑和手机，支持论文年份筛选和点击查看志愿服务证书。2026 年 10 月 17 日核验，无需登录即可访问。空间转录组项目另设展示页，链接见第11节。

学术主页：Google Scholar（陈辰）。

1.2 从课程大纲到具体分析任务

课程报告包括个人主页和数据分析两部分。本作业以空间转录组为例，使用数组运算、表格连接、文件解析、统计建模、机器学习、可视化及网页开发方法。表中列出各项评分要求与作业内容的对应关系，涵盖教学大纲所列专题。

表 1: 评分要求、课程内容与本报告成果的对应关系

评分项目	分值	课程关联	本报告的具体产出
个人主页	20	GitHub 与个人网站	独立 About Me 主页与公开访问核查
数据读取	10	文件输入输出、复杂解析	HDF5、CSV、TSV、JSON 与组织图联合读取
数据预处理	10	NumPy、pandas	质控、标签连接、归一化与特征选择
统计分析	20	SciPy、statsmodels	效应量、FDR、Moran's I、稳健回归
预测模型建立	10	scikit-learn	多数类基线、逻辑回归、随机森林
评估与可视化	20	matplotlib、可解释性	ROC/PR、混淆矩阵、校准、空间误差
项目展示网页	10	网页开发与项目呈现	切片/基因/预测交互图、指标与下载入口

1.3 研究问题与分析边界

本研究考察表达数据与皮层分层的对应关系：层相关基因在两张切片上是否呈现相似分布，局部邻域平滑能否改善聚类，以及表达分类器在另一张切片上的预测误差如何分布。

预测目标为 L1–L6 与白质（white matter，WM）七类解剖标签，观察单位为 Visium 捕获点。主流程采用课程涉及的统计和机器学习方法，扩展分析进一步考察跨片表达一致性、连续空间结构、聚类稳定性及图像特征的增量价值。分析流程见图1。

图 1: 分析流程与跨切片验证设计。条码和坐标核对后，分别开展空间表达分析与跨切片预测。预测流程的特征筛选、标准化和 PCA 均在开发切片 151673 上拟合，固定后应用于留出切片 151674；参考分层用于统计比较、模型训练和性能评估。

2 第二部分：空间转录组的研究背景与方法综述

2.1 组织位置与表达解释

常规转录组描述“哪些基因表达”，空间转录组进一步回答“这些表达发生在哪里”。在皮层中，相似转录特征可能沿组织深度分布；在肿瘤等组织中，细胞状态还可能与边缘、间质或局部微环境相关。组织位置有助于区分这些表达模式。Ståhl 等的工作将组织切片与空间条码测序联系起来，为高通量空间表达分析提供了代表性技术路径 [1]。Rao 等从组织结构出发梳理了空间转录组的分析问题，强调应把表达模式置于具体组织环境中理解 [2]。

技术选择存在分辨率、基因覆盖、视野范围和成本之间的权衡。测序式方法通常具有较广的转录本覆盖，而成像式方法可提供更精细的位置读出，但面板设计、成像循环和计算解码也引入新的约束。Moses 与 Pachter 的综述将不同技术放在历史发展背景中讨论，讨论了分辨率、检测能力和实验条件的共同影响 [3]。本报告选择已有计数矩阵和组织图的 Visium 切片，重点放在下游数据处理与统计推断。

2.2 DLPFC 数据与研究设计

Maynard 等在人脑背外侧前额叶皮层（dorsolateral prefrontal cortex，DLPFC）中建立了空间表达资源，包含三名供体的 12 张切片，并对皮层层次和白质提供了参考注释 [4]。层状组织结构为结果评估提供了直观对象：模型得到的空间区域是否连续，是否能够区分灰白质，以及在相邻层之间是否仍保留模糊边界。这些问题适合通过图像、表达和标签的配对观察来回答。

本报告只使用其中 151673 与 151674，两者在元数据中同属 Br8100、相同组织位置、不同相邻重复切片。其中 151673 用于开发，151674 用于留出评估。相邻切片共享供体与局部组织背景，故这种设计比单片随机切分更接近跨切片使用情境，却仍不足以评价跨人群泛化。

2.3 从表达聚类到空间建模

单纯表达聚类通常先进行归一化和降维，再根据表达相似性划分区域。它易于解释，也能作为判断复杂模型增益的基准，但可能产生空间上零散的簇。空间模型则通过邻域图、先验或图神经网络，让相邻捕获点的信息参与表示学习或聚类。关键问题是如何利用邻域而不把真实边界过度平滑。

表2概括相关工具的建模思路及适用问题。各研究使用的数据和评价方案不同，本文仅比较方法设计。

表 2: 代表性空间转录组工具与本报告的关系

方法或资源	核心作用	对本报告的启发与限制
SCANPY[5]	大规模单细胞表达处理框架	参考模块化预处理思想；实际使用 SciPy 与 sklearn 实现
Squidpy[6]	联合空间分子数据、图像与空间统计	邻域图与空间自相关应独立于二维降维图检查
BayesSpace[7]	在空间先验下聚类并探索亚点位结构	空间连续性有助于区域识别；推断精细结构不等于新增实测分辨率
SpaGCN[8]	整合表达、空间位置和组织学信息的图卷积	图像可作为信息来源；需避免把组织图仅作为装饰
STAGATE[9]	自适应图注意力自编码器学习空间表征	邻居贡献可以自适应；训练复杂度和参数选择需另行控制
SEDR[10]	联合表达表征和空间图的深度嵌入	提供可追溯的整理数据；本项目不将其已有聚类作为输入
spatialLIBD[11]	组织图、表达与分层注释的交互探索	数据来源与参考标注可核查，是本项目溯源基础

2.4 整合单细胞信息的价值与边界

混合捕获点的表达受细胞类型组成和细胞状态共同影响。单细胞参考图谱可以帮助解释这种混合，而反卷积模型估计的是给定参考和模型假设下的细胞类型贡献。Longo 等梳理了单细胞与空间数据整合的分析路径 [12]；cell2location 提供了细胞类型空间映射的代表性建模框架 [13]。Lohoff 等的胚胎研究展示了两类数据联合使用的生物学价值 [14], Huuki-Myers 等进一步扩展了人前额叶单细胞与空间图谱资源 [15]。

本次分析使用捕获点级表达，未引入单细胞参考。层相关信号可提示局部组织组成，但细胞比例的估计仍需反卷积模型和匹配的参考数据。

2.5 从高通量测序到原位成像：技术路线的比较

Slide-seq 用已知位置的条码微珠捕获组织 RNA，Slide-seqV2 进一步提高了检测灵敏度 [16-17]。HDST 采用高密度空间条码阵列 [18]；Stereo-seq 以 DNA 纳米球阵列实现大视野空间测量，并用于构建小鼠器官发生图谱 [19]。这些技术在采样间距、转录本捕获能力和覆盖范围上各有侧重。下游分析需要据此选择计数聚合尺度，并检查组织制备和测量稀疏性对结果的影响。

MERFISH 利用组合编码和多轮成像定位 RNA[20]，seqFISH+ 将原位 RNA 成像扩展到转录组尺度 [21]。成像方法提供精细的分子位置，其结果仍受探针设计、背景、解码和细胞分割影响。Visium 捕获点、原位 RNA 分子与分割细胞属于不同观察单位，比较研究结果时需保留这一区别。

表 3: 代表性技术路线及其对下游分析的要求

路线	提供的信息	分析时需要保留的区别
ST / Visium	组织切片上的空间条码计数	捕获点通常混合多个细胞；配准和测序深度影响解释
Slide-seq / V2	微珠位置与转录计数	小采样单元仍可能稀疏；分辨率与检测能力共同决定可用信息
HDST / Stereo-seq	高密度阵列与较精细的空间读出	聚合尺度、组织边界与计数稀疏性需一起报告
MERFISH / seqFISH+	RNA 原位成像及空间定位	探针面板、解码与细胞分割影响最终观察单位

2.6 组织图谱、疾病研究与多模态整合

Hawrylycz 等建立的人脑转录图谱揭示了解剖区域与分子表达的对应 [22]；Yao 等和 Zhang 等的全小鼠脑图谱进一步将细胞类型与空间组织联系起来 [23-24]。图谱研究依赖多基因模式和区域重复性，而非单个基因的局部高表达。这也为本次跨片相关和多尺度分析提供了依据。

Asp 等整合空间转录组、单细胞测序与原位测序，构建人胚胎心脏图谱 [25]。Ji 等结合单细胞、空间分析及蛋白成像，研究皮肤鳞状细胞癌的组织结构 [26]；Moncada 等则在胰腺导管腺癌中联合空间与单细胞数据分析组织组成 [27]。这些研究展示了不同模态相互验证的作用，其具体疾病机制与本次脑皮层分析有所不同。

在计算层面，RCTD 针对混合空间测量分解细胞类型贡献，并考虑测序平台差异 [28]；Tangram 将单细胞或单核转录组与空间数据对齐 [29]。Hao 等提出的多模态单细胞分析框架则提示，不同模态对不同细胞的贡献可能不同 [30]。因此，增加图像特征只是构建联合模型的第一步，还需要用相同数据划分比较单模态和联合模型。本报告据此增加一个简单、可解释的图像消融实验；它不是上述整合算法的复现。

2.7 空间变异基因与统计尺度

层间差异和空间变异回答不同的问题。前者需要先给出分组，后者检验表达是否随位置呈现结构。SpatialDE 通过空间统计模型识别空间变异基因 [31]；trendsceek 从带有表达标记的空间点过程出发研究表达趋势 [32]。一个基因即使没有清晰的分层均值差异，也可能在层内形成局部区域；反过来，显著的层间差异也可能部分来自人工分组方式。

本次分析采用层与其余点的表达对比、Moran's I、多半径邻域和几何深度曲线，分别描述分组差异、局部相似性及连续变化。SpatialDE 和 trendsceek 作为方法背景介绍，未用于本次计算。

2.8 组织图与定量比较

Maynard 等将切片形态与代表基因空间分布并列展示 [4]；Slide-seq 研究结合整体和局部视野观察表达模式 [16]。Asp 等通过空间检测与原位验证比较结果 [25]，Zhang 等则将组织位置与细胞邻近关系结合分析 [24]。这些研究中的图像承担了定位和比较的作用。本次分析也将组织视野与定量结果配对：局部 H&E 对应跨片表达比较，参考层位置对应邻域统计，预测图对应误差分析。

各图使用一致的参考层颜色；同一基因在两片间共享表达色阶。H&E 局部视野从作者图像直接裁剪，空间表达图和预测图保持原始切片方向。图注说明点大小、色阶和区间的含义。

3 数据来源、读取与图像配准

3.1 数据构成与来源追踪

输入文件包括五类：过滤后的基因–条码计数矩阵（HDF5）、H&E 组织图（PNG）、捕获点空间位置表（CSV 格式）、图像缩放参数（JSON），以及人工分层标签（TSV）。矩阵和组织图从作者项目所列的 AWS 地址取得，位置和缩放参数来自 HumanPilot 原作者仓库。主要标签使用该仓库的 `10X/barcode_level_layer_map.tsv`；另读取 SEDR 分析仓库的元数据，仅用于条码、标签、坐标、UMI 和供体信息交叉核对。

原始文件保存在 `data/raw/`，程序只读；每个下载文件的 URL、字节数、SHA256 和访问日期记录于 `data/manifest.json`。组织图采用作者发布的 2000 × 2000 像素 hires 缩小图，并非扫描仪全分辨率 TIFF。表达输入为上游 Space Ranger 处理后的计数矩阵。

表 4: 两张切片的输入规模与筛选结果

指标	151673（开发）	151674（留出）
供体	Br8100	Br8100
捕获点数	3639	3673
基因数	33538	33538
有分层标签的点	3611	3635
通过质控的点	3629	3671
最终进入分析的点	3601	3633
UMI 中位数	4120	5334
检测基因数中位数	2113	2610
线粒体比例中位数（%）	16.65	15.61

3.2 稀疏矩阵与条码连接

HDF5 中的 `data`、`indices`、`indptr` 和 `shape` 共同描述压缩稀疏列矩阵。读取后转置为“捕获点 × 基因”的 CSR 矩阵，便于按点过滤和求和。两张切片的零值比例约为 93.4% 与 92.0%，稀疏存储避免了过早构造大而稠密的矩阵。直到选出 2,000 个特征后，才为标准化和 PCA 建立较小的稠密数组。

条码是各文件之间的连接键。程序先检查条码唯一性，再按表达矩阵中的顺序重排位置与标签表；不同切片使用各自的条码空间，不能仅凭相同条码字符串把两张切片混为同一个观察。还额外检查重新计算的 UMI 总量是否与独立元数据一致，以及作者标签是否与整理版标签逐点一致。缺少标签的点单独保留在全点质控表中，不把它们当作某个皮层类别。

3.3 坐标缩放与切片方向

位置表包含阵列行列号和全分辨率图像像素坐标。假设全图的横向和纵向坐标为 x_i^{full}、y_i^{full}，缩放系数为 s，则用于 hires 图的坐标是

$$x_i = s x_i^{\text{full}}, \qquad y_i = s y_i^{\text{full}}. \tag{1}$$

两张切片的 hires 系数均为 0.150015。像素行对应纵轴，像素列对应横轴；显示时保持图像坐标的纵轴向下，不额外旋转或翻转。程序还将缩放后的坐标与整理版低分辨率坐标换算比较，以发现行列交换或比例错误。图2按同一视野并列展示组织图、标注叠加和纯空间标签图，既保留形态信息，也便于检查位置对应。

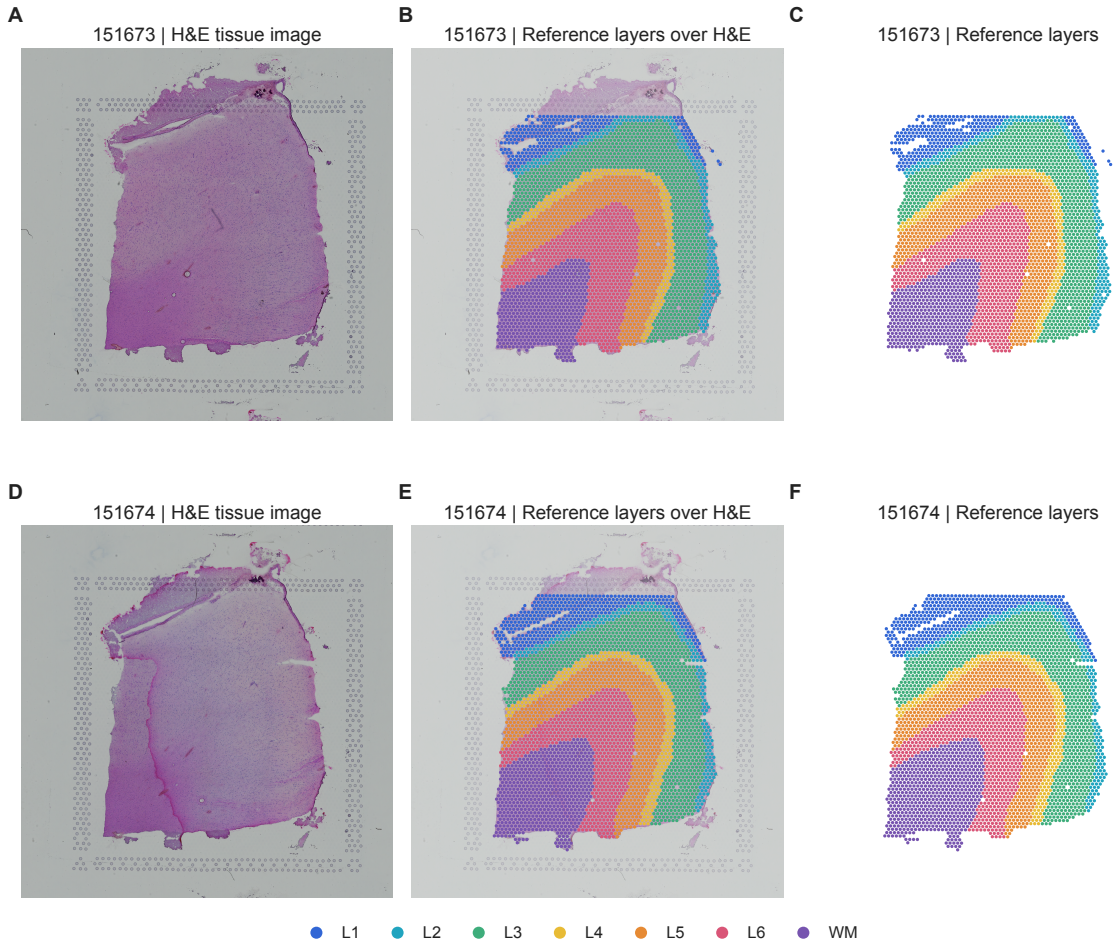

图 2: 两张切片的 H&E 组织图与参考分层。各行依次为作者发布的 hires 图、参考标签叠加图及标签图；颜色区分 L1–L6 和白质。数据来源：Maynard 等及 HumanPilot。

4 预处理：从质量控制到训练集内降维

4.1 质量指标与预先固定的规则

每个捕获点计算三个指标：总 UMI 数 $N_i = \sum_g c_{ig}$、检测到的基因数 $G_i = \sum_g \mathbb{1}(c_{ig} > 0)$，以及以 `MT-` 开头基因的计数占比。主分析采用组织内点、UMI 不低于 500、检测基因数不低于 250、线粒体比例不高于 30% 的规则。各阈值在本次分析前固定。

151673 有 10 个点未通过质控，151674 有 2 个点未通过质控；另分别有 28 和 38 个点缺少参考层标签。取通过质控且标签完整的交集，最终纳入 3601 和 3633 个点。图3展示总体分布和各层保留率，图4进一步展示层组成及质量差异。各层共用同一套质控阈值，以保留灰白质间可能具有生物学意义的 RNA 含量差异。

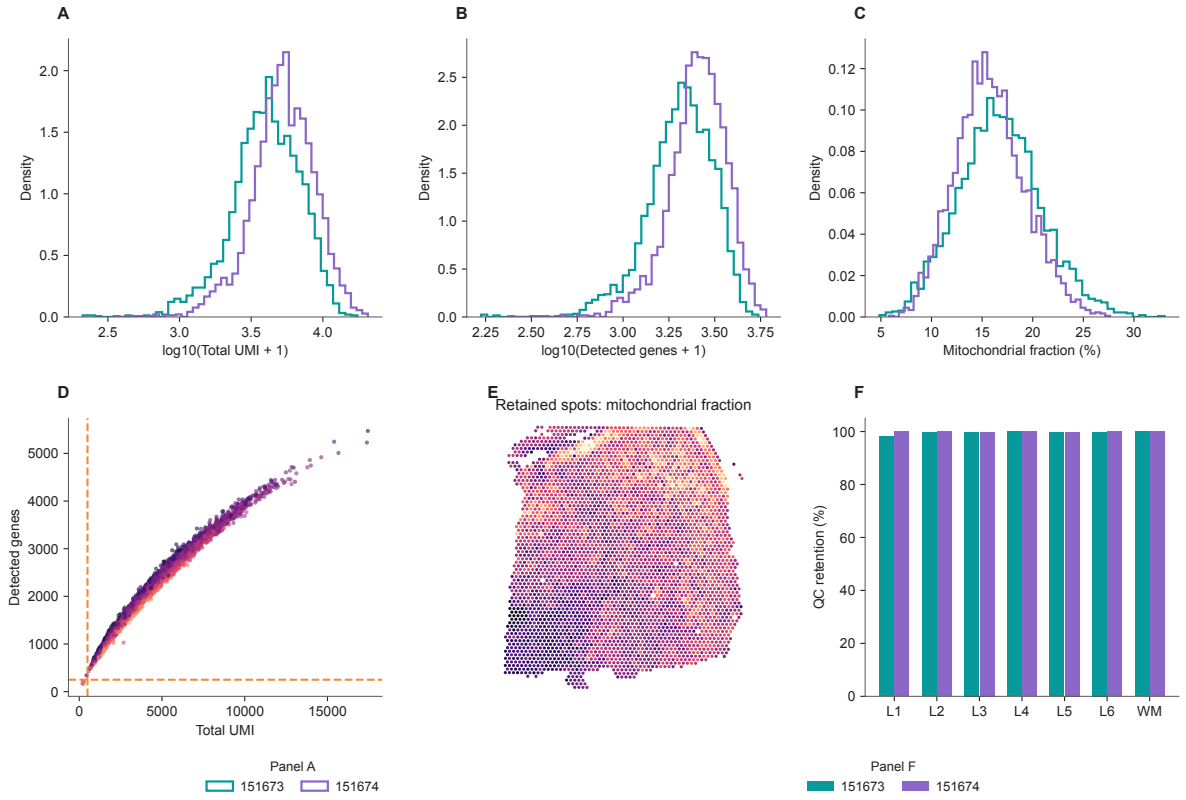

图 3: 质控诊断。上排比较两张切片的 UMI、检测基因数和线粒体比例分布；下排展示开发切片的 UMI–基因数关系、保留点的线粒体比例空间分布及各层质控保留率。散点图颜色表示线粒体比例；虚线为最低 UMI 和基因数阈值。

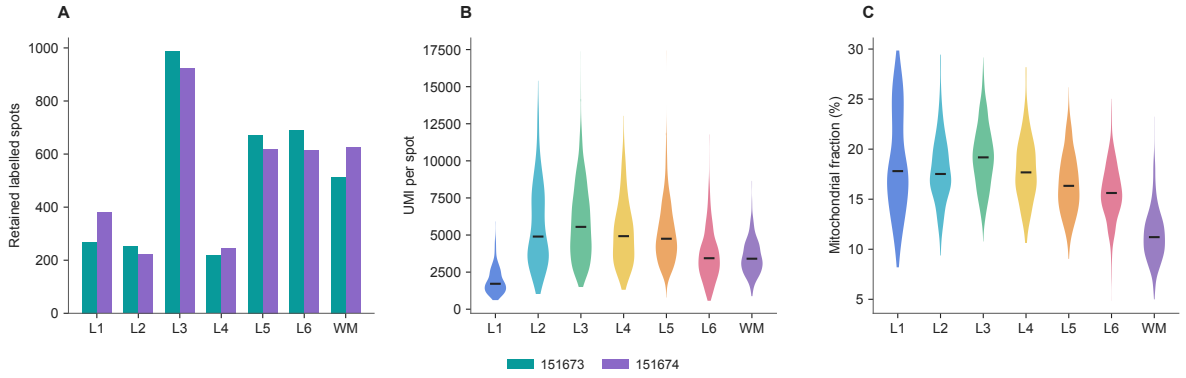

图 4: 各层点数与质量指标。A：两片各层保留点数。B、C：开发片的 UMI 与线粒体比例分布，中线为中位数。

4.2 归一化、对数变换与高变特征

为降低测序深度差异的影响，采用每点总计数归一化到 10^4，并进行自然对数变换：

$$x_{ig} = \log\left(1 + \frac{10^4 c_{ig}}{\sum_{g'} c_{ig'}}\right). \tag{2}$$

该处理改善不同深度捕获点之间的可比性，但不是绝对分子数校正；输入中的零值仍可能同时反映真实低表达与测量稀疏性。

特征选择在每次划分的训练子集内完成。保留至少在 20 个训练点检出的基因，排除 `MT-`、`RPL`、`RPS` 前缀基因，再按平均对数表达划分最多 20 个等频区间。在各区间内标准化方差与均值之比，选取得分最高的 2,000 个基因。该均值分箱离散度算法的具体实现见附录。

用训练均值和标准差缩放选中基因，并将标准化值截断到 $[-10, 10]$ 以减少极端值影响，随后拟合 50 个主成分。测试数据仅使用训练获得的基因列表、缩放参数和 PCA 载荷做变换。逐点总量归一化本身不估计跨样本参数，可以分别计算；基因筛选、均值、标准差和 PCA 则必须遵守训练边界。

4.3 可复现配置与泄漏防范

主流程的随机步骤固定种子 20261012，随机森林限制为 2 个并行任务。模型不使用阵列坐标、H&E 像素、已有聚类结果或人工层标签作为特征。标签仅用于监督训练和评估，坐标用于独立的空间分析、空间切分和误差定位。每次切分均重新拟合预处理器，避免先在完整数据上选基因再评估带来的信息泄漏。

训练与测试之间仍存在生物学依赖：两片来自同一供体，参考层注释也结合了表达信息。这些限制在讨论中进一步说明。

5 统计分析：层相关表达与空间自相关

5.1 预先指定的标志基因面板

我们选择 12 个具有解释价值的基因进行探索：RELN、CUX2、RORB、PCP4、NTNG2、MBP、MOBP、SNAP25、AQP4、GFAP、PLP1 和 SLC17A7。面板关注皮层层次、神经元相关表达与髓鞘/胶质相关表达，不是穷尽性的差异基因发现。图5给出其中六个基因在两张切片上的位置图；同一基因跨切片使用共同的第 99 百分位数作为颜色上限，以支持直接比较，同时减少少量极端值对色阶的挤占。

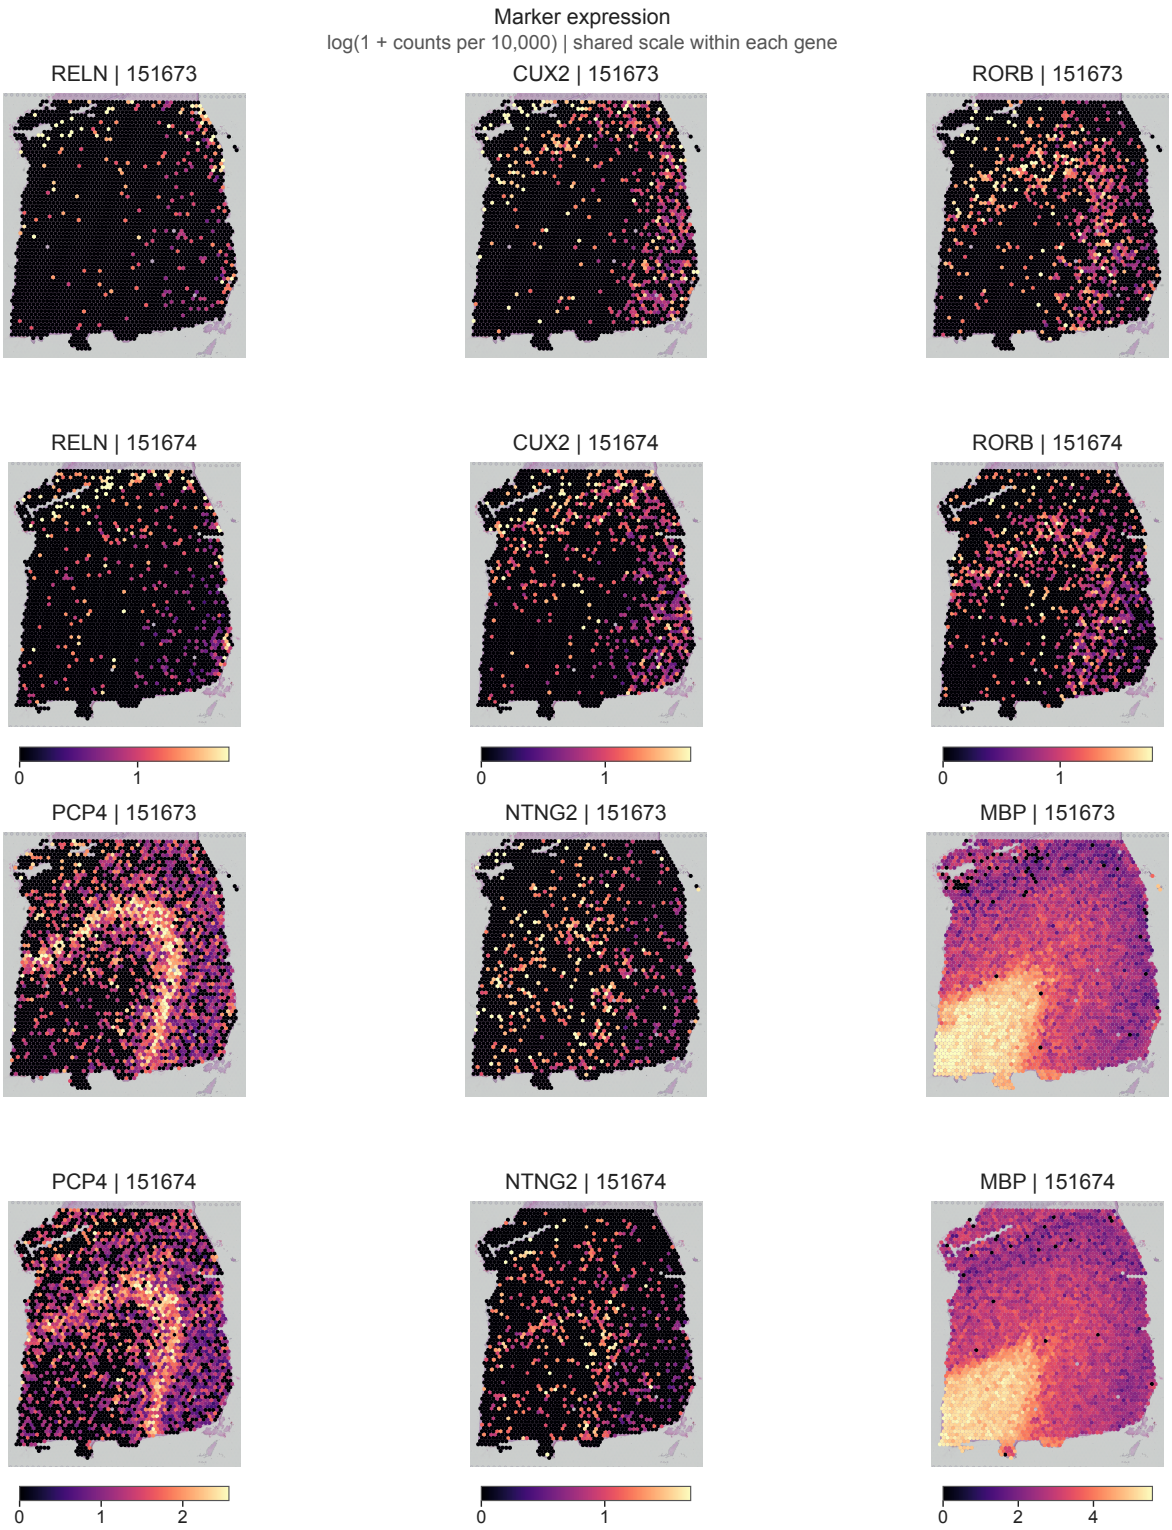

图 5: 六个预设基因的空间表达。颜色表示 $\log(1 + \text{CP10K})$，同一基因跨片共享色阶，上限为合并表达的第 99 百分位。底图为作者发布的 H&E 图。

5.2 层间检验、效应量与多重比较

对于每个基因，使用 Kruskal–Wallis 检验比较七类参考层的表达分布，并以

$$\epsilon^2 = \max\left(0, \frac{H - K + 1}{n - K}\right), \qquad K = 7, \tag{3}$$

作为描述性效应量。每张切片的 12 个基因构成一个预先限定的检验族，使用 Benjamini–Hochberg 方法控制该族的错误发现率 [33]。这不是全转录组水平的 FDR 分析。

捕获点在空间上相关，经典秩检验的独立性假设并不充分成立，因此小 q 值只作为描述性证据；本文更重视效应量、空间图和跨切片模式的一致性。表5可见 MBP 的效应量约 0.672，明显大于 RELN 的 0.042 与 NTNG2 的 0.017。尽管后两者也可能获得很小的检验概率，其低检出率和较弱的层区分度意味着它们在本数据中并非同样稳定的单基因标志。极小概率以小于计算阈值的形式报告。

表 5: 开发切片 151673 的预设基因统计结果

基因	检出率（%）	ϵ^2	Moran I	KW 校正 q
RELN	6.3	0.042	0.089	5.3×10^{-31}
CUX2	14.7	0.114	0.118	1.7×10^{-86}
RORB	19.3	0.088	0.123	2.4×10^{-66}
PCP4	47.8	0.217	0.302	3.5×10^{-166}
NTNG2	14.6	0.017	0.048	1.8×10^{-12}
MBP	98.1	0.672	0.805	$< 10^{-300}$
MOBP	45.4	0.462	0.643	$< 10^{-300}$
SNAP25	97.7	0.352	0.443	2.3×10^{-271}
AQP4	45.3	0.079	0.116	1.2×10^{-59}
GFAP	82.5	0.474	0.626	$< 10^{-300}$
PLP1	90.5	0.549	0.695	$< 10^{-300}$
SLC17A7	89.1	0.171	0.211	2.3×10^{-130}

KW：Kruskal–Wallis 检验；检出率为归一化前计数大于零的比例。概率与 q 值为点级探索量，不能解释为供体层面的独立验证。

5.3 Moran's I 与空间邻域图

空间表达图中的连续区域需要定量检验。用 hires 坐标建立无向邻接图：相距不超过“全体点最近邻距离中位数的 1.15 倍”时连接两点。对规则 Visium 阵列，该阈值近似保留直接相邻点，并避免在缺失区域强行寻找固定数量远邻。开发切片有 10,465 条无向边，留出切片有 10,555 条；开发切片存在 1 个孤立点，平滑时保留其原表示。

对中心化表达 $z_i = x_i - \bar{x}$，计算

$$I = \frac{n}{S_0} \frac{\sum_i \sum_j w_{ij} z_i z_j}{\sum_i z_i^2}, \qquad S_0 = \sum_i \sum_j w_{ij}. \tag{4}$$

在固定图上随机置换表达 999 次，计算右尾概率 $p = (1 + \#\{I_b \geq I_{\text{obs}}\})/1000$，并在每片的 12 个基因内进行 BH 校正。全部预设基因的右尾概率均达到本次置换可分辨的下限 0.001，但空间自相关强度差异较大：MBP 的 $I = 0.805$，MOBP 为 0.643，NTNG2 为 0.048。

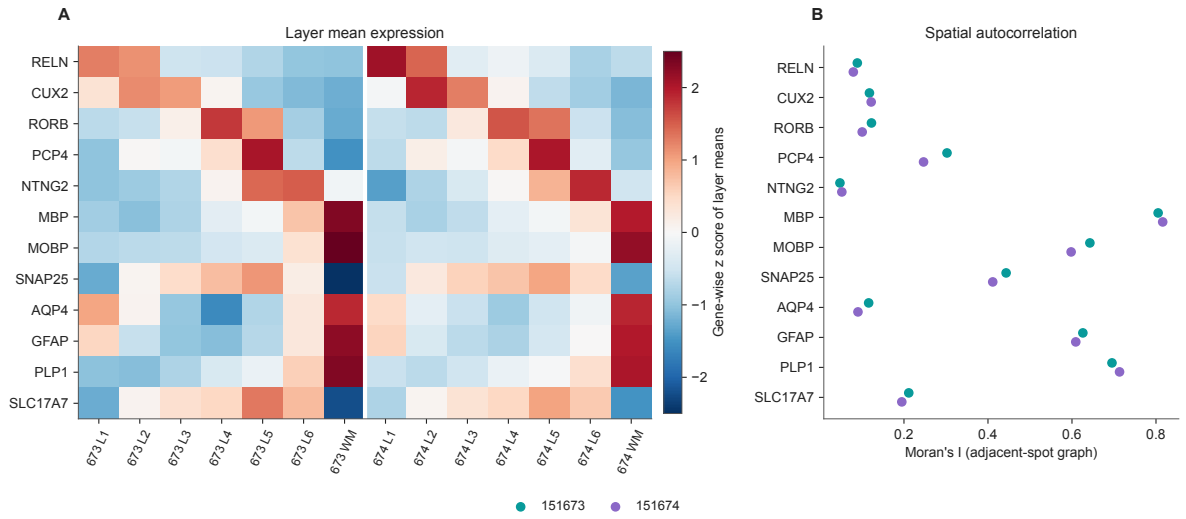

图 6: 层平均表达与空间自相关。A：按基因标准化的 14 个“切片–层”表达均值。B：两片 Moran’s I；999 次置换的概率下限为 0.001。

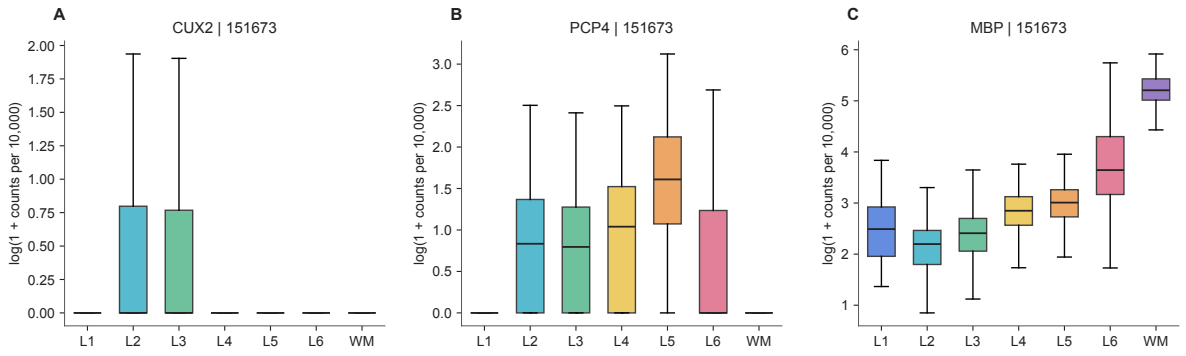

图 7: 开发片 CUX2、PCP4 与 MBP 的层间分布。箱体为四分位区间，中线为中位数，须线延伸至距箱体不超过 1.5 倍四分位距的最远点；离群点未单独绘出，全部点参与统计。

5.4 以 MBP 为例的调整模型

为演示 statsmodels，进一步在开发切片拟合

$$x_{i,\mathrm{MBP}} = \beta_0 + \sum_{k \neq \mathrm{L1}} \beta_k \mathbb{1}(L_i = k) + \gamma \log(1 + N_i) + \delta m_i + e_i, \tag{5}$$

其中 m_i 为线粒体百分比，L1 为参照。按阵列行每 10 单位、列每 20 单位形成空间网格块，对回归协方差作块聚类稳健估计。调整后 WM 相对 L1 的对数归一化表达差异为 3.183，95% 区间为 [2.933, 3.433]。这一差异与空间图所示白质区域相符，但依然是当前切片上的条件关联，不能解释为白质对表达的因果效应。

网格稳健协方差用于修正块内相关对标准误的影响。由于相邻块仍可能相关，且分析仅涉及一个供体，该区间用于描述当前切片上的调整关联。

6　降维与空间区域识别

6.1　低维表达结构

开发切片上 50 个主成分累计解释所选标准化基因变异的 11.8%。PCA 提供可投影到测试数据的线性表示，t-SNE 则用于观察开发切片的局部表达邻近关系；本项目 t-SNE 设置 perplexity 为 30、迭代上限 1,000 次。二维图中的距离和簇间空白受方法参数影响，不应被直接理解为组织距离或发育轨迹。图8的颜色只用于后验显示参考层，没有参与无监督降维的拟合。

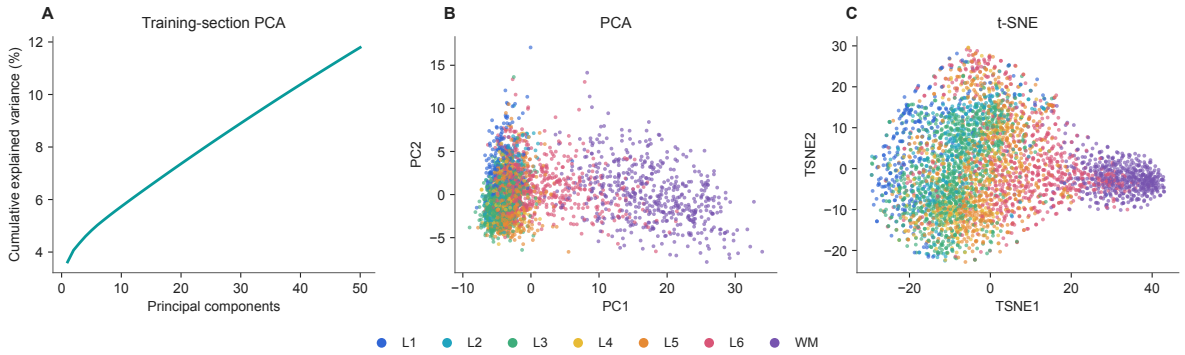

图 8: 开发片降维结果。A：PCA 累计解释方差。B、C：PCA 与 t-SNE 二维嵌入，颜色表示参考层。

6.2　表达聚类与邻域平滑聚类的直接对照

采用两个可理解的基线。第一，在 50 维 PCA 表示上做 $K = 7$ 的 KMeans；第二，先将每个点的表示与其直接邻居均值各取一半，再对新表示做相同的 KMeans：

$$\tilde{\mathbf{z}}_i = 0.5\mathbf{z}_i + 0.5\frac{1}{d_i}\sum_j w_{ij}\mathbf{z}_j. \tag{6}$$

孤立点保持原表示。$K = 7$ 来自本研究预定的七层对照任务，因此是对区域数的先验；没有使用逐点标签训练聚类。两个方法均使用 20 次初始化和固定随机种子，没有依据参考标签反复挑选参数。

表达聚类的 ARI 为 0.174，邻域平滑后为 0.222；NMI 相应由 0.324 提高到 0.400。空间邻域改善了连续性，与参考层的绝对一致性仍较低。图9为便于比较，用匈牙利匹配在聚类完成后对齐簇颜色；该匹配只改变显示颜色，不参与聚类，ARI/NMI 本身对簇编号置换不敏感。

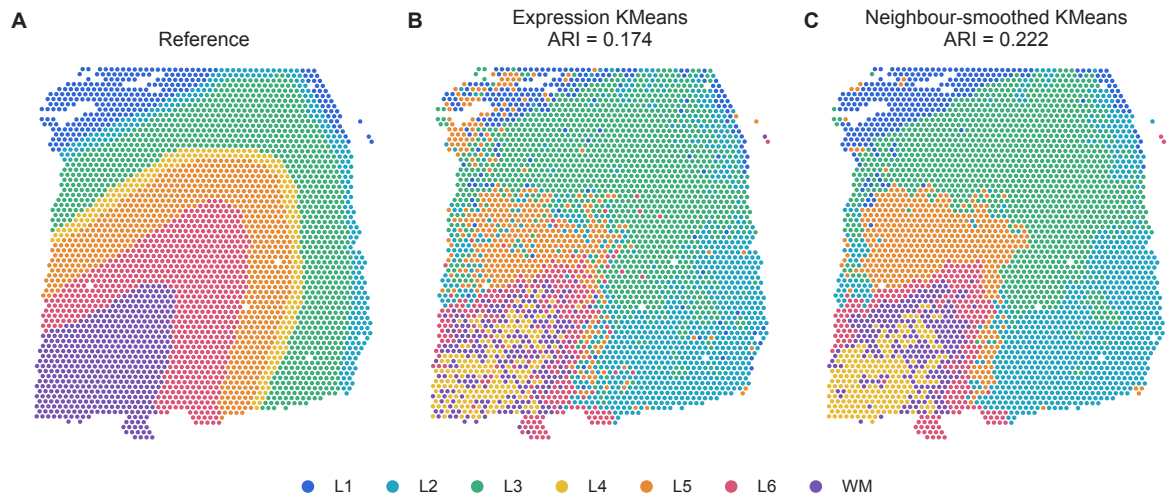

图 9: 参考分层、表达 K-means 与邻域平滑 K-means 的空间分布。两种聚类均设七簇；簇颜色在拟合后通过匈牙利匹配对齐至参考层。

7　预测模型建立与评估

7.1　任务定义、模型与固定参数

监督任务是用捕获点的表达特征预测 L1–L6 或 WM。多数类模型恒预测开发集最常见类别，衡量“完全不学习表达”的表现；逻辑回归使用 50 维 PCA 特征、$C = 1$、类别平衡权重和最多 2,000 次迭代；随机森林使用 300 棵树、最小叶节点 3、每次分裂考虑特征数为总数平方根，并采用 `balanced_subsample` 权重。随机森林作为非线性对照，其袋装与随机特征选择思想来自经典方法 [34]。

参数在评估前固定，未根据留出片结果调参。逻辑回归为主要诊断模型，随机森林和多数类模型作为对照。后续分别检查其混淆矩阵、概率表现与误差位置。

7.2　验证设计

第一种是开发片内分层随机切分：2,700 个点训练，901 个点测试。它主要衡量同一片中的插值能力，邻近点相关性可能使指标乐观。第二种是开发片内空间网格块留出：固定随机选择 25% 的块形成测试集，得到 2,558 个训练点和 1,043 个测试点，避免同一块同时出现在两侧，但没有设置块间缓冲带。

第三种为主评估：用开发片全部 3601 个合格点训练，在留出片的 3633 个点上评估。空间相关数据的验证策略应与目标使用情境匹配 [35]。这里的主评估对应同供体相邻切片，而不是新供体。三种设置的训练规模也不同，不能把数值差异完全归因于空间泄漏。

7.3　整体性能与不确定性

表6给出主评估结果。逻辑回归准确率为 0.563、宏 F1 为 0.536，均优于多数类基线。随机森林的宏 F1 为 0.468，说明模型复杂度增加并未在该设置下带来更好结果；可能原因包括样本规模、类别不平衡、所用低维表示及层间连续变化，但本实验未对这些原因作独立消融。

表 6: 留出切片 151674 上的七分类性能

模型	准确率	平衡准确率	宏 F1	宏 AUROC	宏 AP
多数类基线	0.254	0.143	0.058	0.500	0.143
逻辑回归	0.563	0.562	0.536	0.896	0.586
随机森林	0.555	0.460	0.468	0.865	0.536

对留出切片的 46 个空间网格块进行有放回抽样，重复 500 次；每次保留抽中块内全部点，计算宏 F1，得到逻辑回归的百分位区间 [0.491, 0.559] 和随机森林的 [0.426, 0.501]。这些区间描述固定模型在当前切片空间组成变化下的条件不确定性，不包含训练集重采样、供体间变化或所有块间相关，因此不是人群泛化性能的置信保证。

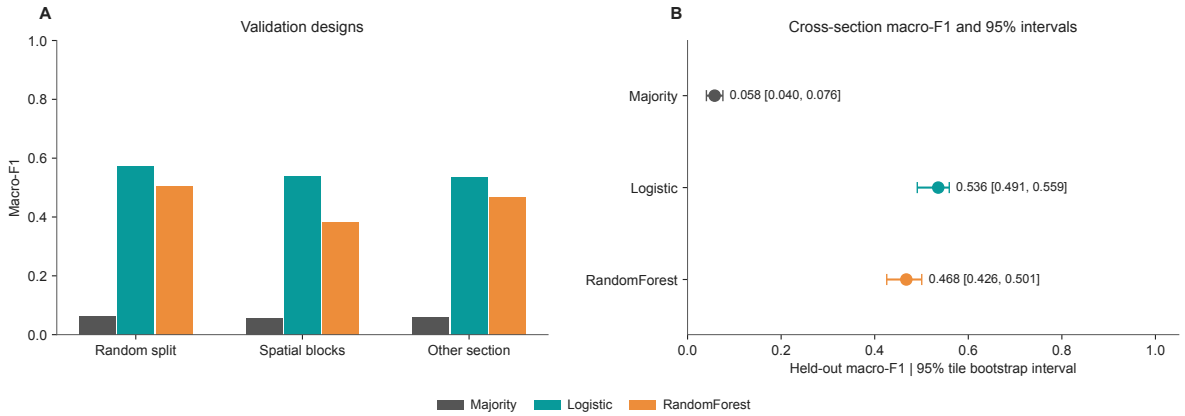

图 10: 模型在不同验证设计下的表现。A：片内随机、空间块留出及跨片宏 F1。B：跨片宏 F1 及 500 次空间块 bootstrap 的 95% 百分位区间。

7.4 各层分类表现

逻辑回归在 WM 上的 F1 为 0.896，在 L1 上为 0.727，而 L4 仅为 0.196。表7和图11显示，整体成绩受易识别白质与难区分相邻皮层共同影响。L2 的召回率约为 0.589，但精确率仅为 0.278；L3 的精确率约为 0.670，但召回率约为 0.322。这样的不对称说明单一准确率无法表达不同层的误差性质。

表 7: 逻辑回归在留出切片上的分类别表现

层	点数	精确率	召回率	F1
L1	380	0.705	0.750	0.727
L2	224	0.278	0.589	0.378
L3	923	0.670	0.322	0.435
L4	247	0.190	0.202	0.196
L5	620	0.435	0.574	0.495
L6	614	0.585	0.668	0.624
WM	625	0.977	0.827	0.896

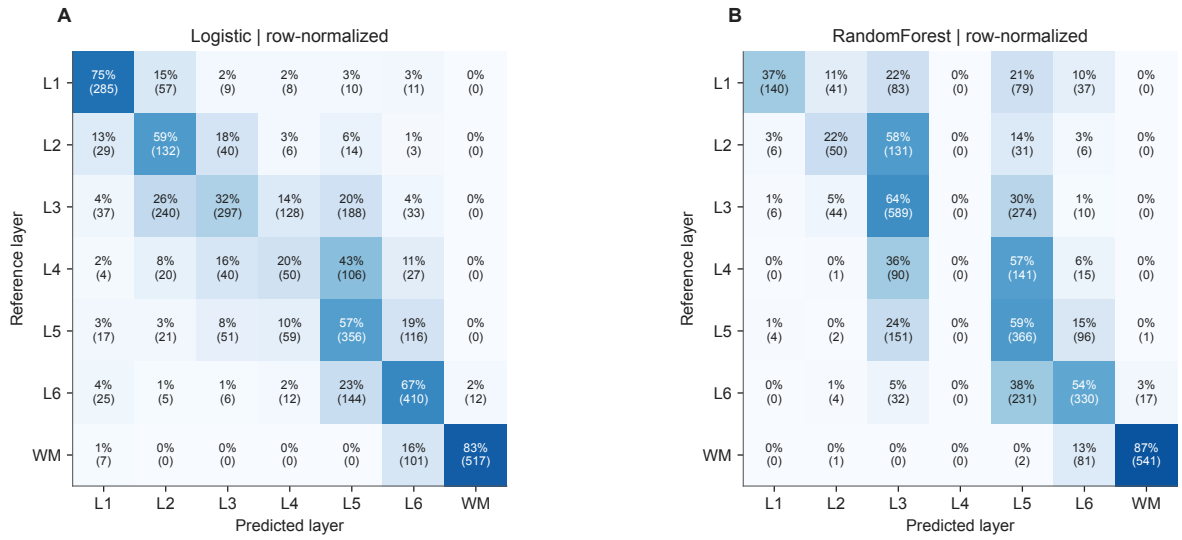

图 11: 留出片混淆矩阵。行表示参考层，列表示预测层；各单元格标注行内百分比与点数。

7.5 ROC、PR 与类别不平衡

将每个层依次视作阳性，其余层视作阴性，计算 one-vs-rest ROC 和 PR 曲线。逻辑回归的宏 AUROC 为 0.896，宏 AP 为 0.586。较高的 AUROC 与中等的宏 F1 并不矛盾：前者衡量各类相对其余类的概率排序，后者取决于七类 argmax 决策后的实际分配。尤其在相邻层概率接近时，排序可较好而最终分类仍容易出错。

PR 曲线反映阳性预测的精确率与召回率，其基准取决于类别比例。图12同时列出各层 AP，可与混淆矩阵对照，区分概率排序良好与实际分类准确这两种表现。

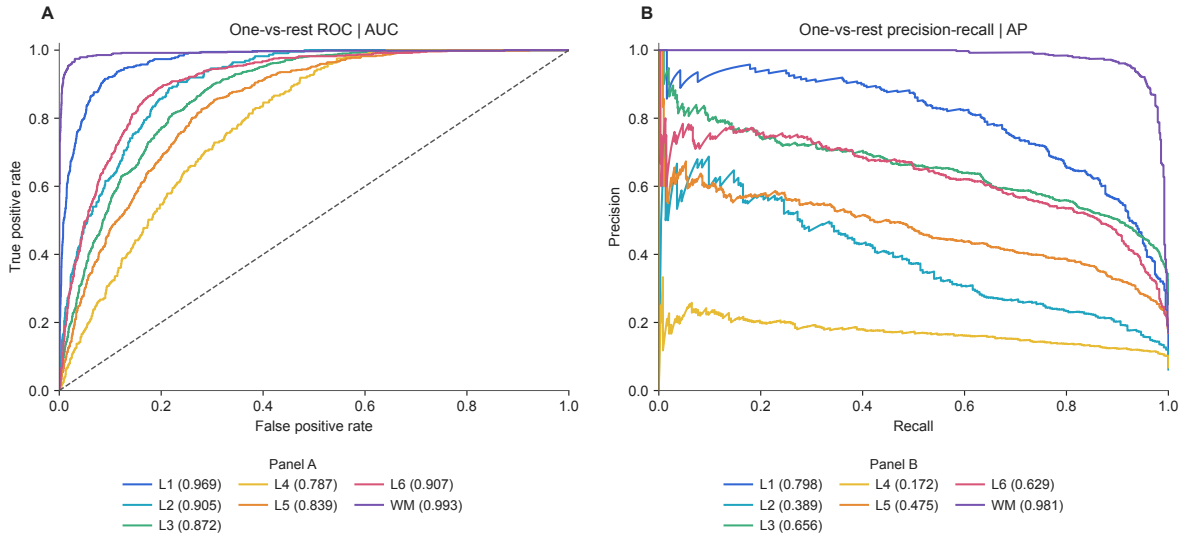

图 12: 留出片逻辑回归的 one-vs-rest ROC 与 PR 曲线。图例列出各层 AUC 和 AP；ROC 对角虚线为随机排序基准。

7.6 校准、预测熵与空间错误定位

将最大预测概率按宽度 0.1 分箱，比较平均置信度与实际正确率，得到 top-label 校准图；空箱不绘制。多分类 Brier 分数定义为 $n^{-1}\sum_i\sum_k(p_{ik}-y_{ik})^2$，逻辑回归为 0.542，随机森林为 0.592，越低越好。这里使用类别求和形式，取值范围为 0–2，不应与类别平均形式混用。两模型的对数损失分

别为 1.047 与 1.221。多数类模型输出硬概率，会对非多数类产生极大的对数损失，因此作为类别基线解读即可。

归一化预测熵定义为 $-\sum_k p_{ik} \log p_{ik} / \log 7$。熵较大说明分配在多个层之间，但低熵不保证预测正确；模型也可能自信地误判。图13展示概率与错误关系，图14把预测重新投影回组织位置。

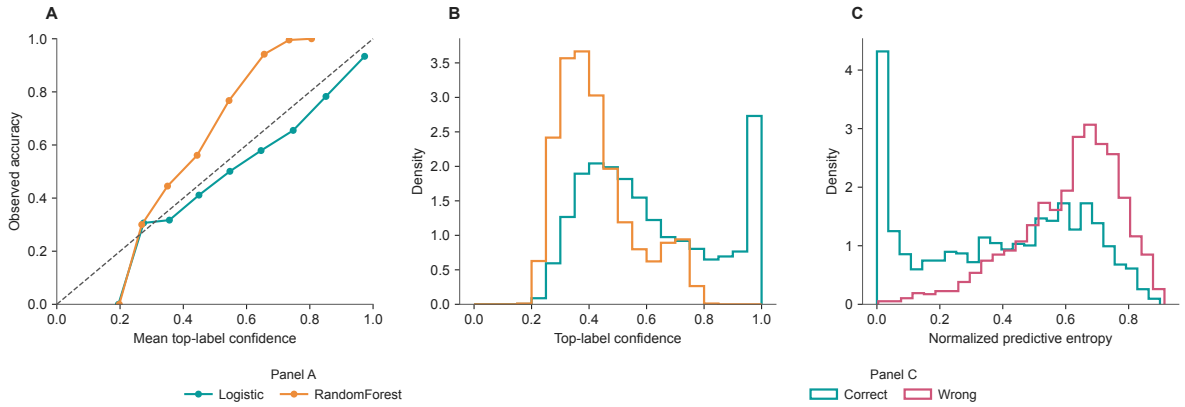

图 13: 留出片概率评估。A：按 0.1 宽度分箱的最大概率与实际正确率。B：最大预测概率分布。C：逻辑回归正确与错误预测的归一化熵。

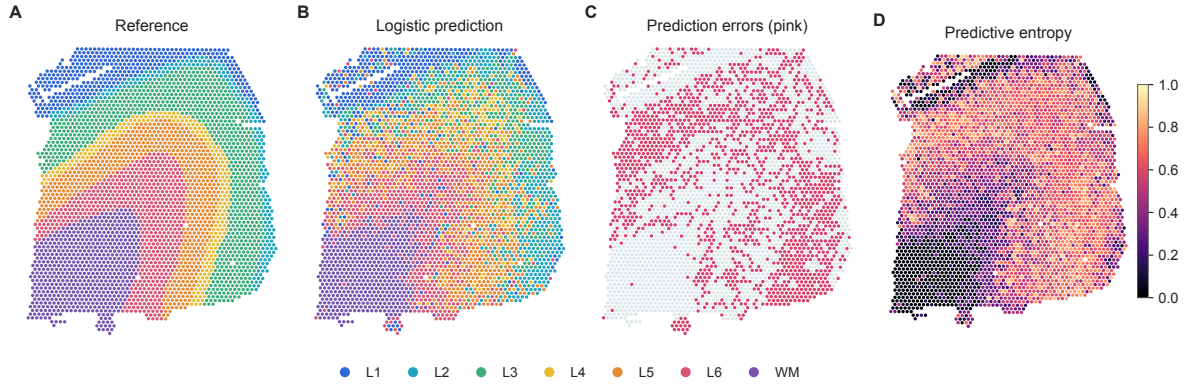

图 14: 留出片参考层、逻辑回归预测、错误位置及归一化预测熵。粉色标记错误点，熵使用连续色阶。

将直接邻域中存在异层邻居的点定义为参考边界点。留出片共有 1,008 个边界点和 2,625 个内部点，逻辑回归错误率分别为 60.1% 和 37.3%。该差异显示，层边界附近的捕获点较难分类。边界标签仅用于误差分析。

7.7 基因系数回投

为联系预测特征与原始基因，将逻辑回归在 PCA 空间的系数乘以 PCA 载荷，得到对标准化且截断后基因表达的线性系数。图15展示最大绝对系数排名靠前的 16 个基因，包括 MOBP 等与空间表达图相呼应的信号，也包括可能反映局部细胞组成或组织状态的特征。相关基因之间共享信息，系数大小还取决于特征筛选和缩放，系数可用于描述预测关联。

本次采用线性系数回投进行解释，未实施课程大纲所列的 SHAP 分析，可直接检查各基因对分类得分的贡献方向。它仍受相关特征和标准化方式影响。图15同时列出 MBP 调整回归的区间，分别呈现预测系数与层间关联。

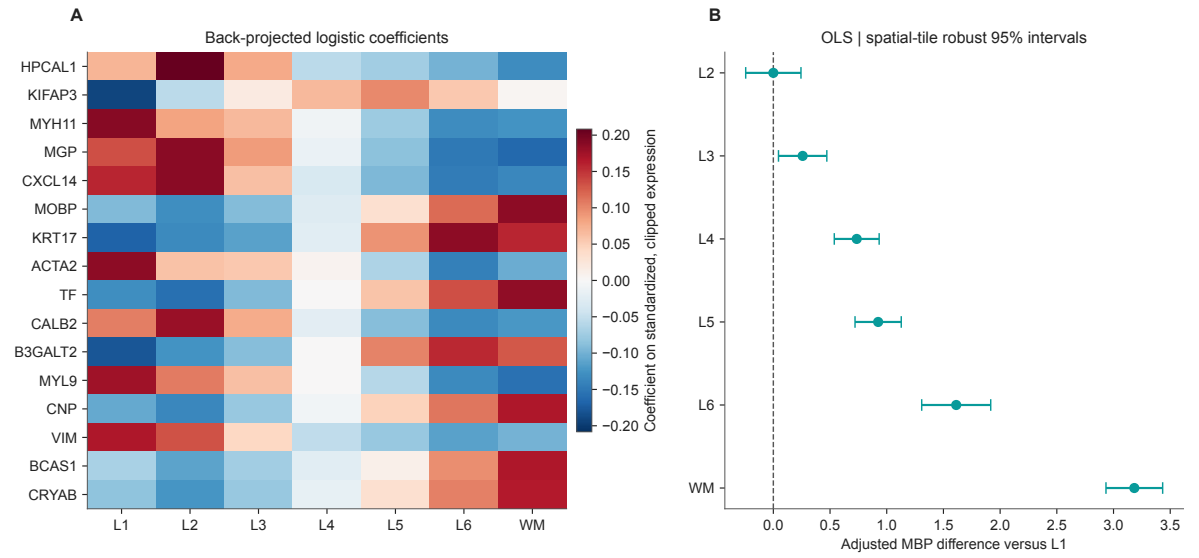

图 15: 基因系数与 MBP 调整关联。A：经 PCA 载荷回投的逻辑回归系数。B：开发片 MBP 相对 L1 的调整差异及空间块聚类稳健 95% 区间。

8　扩展分析一：从局部形态到跨切片表达一致性

8.1　多尺度组织学观察及其作用

前述全切片对照能够检查整体方向，却不容易看清局部纹理。图16在两张切片各选取 L1、L3、L6 和 WM 的局部区域，与整张 H&E 图配对展示。取景时先计算各参考层捕获点的坐标中心，再选择离该中心最近的捕获点，围绕它裁剪 190 × 190 像素的方形窗口。框线颜色与全篇皮层配色一致，因而可以回到完整切片核对取景位置。

局部视野显示了染色、纹理与血管样结构的差异。两片按各自层中心取景，局部结构未必一一对应。图像保持原生像素，标尺为 hires 图的 50 像素；本次未进行细胞核分割或细胞密度定量。

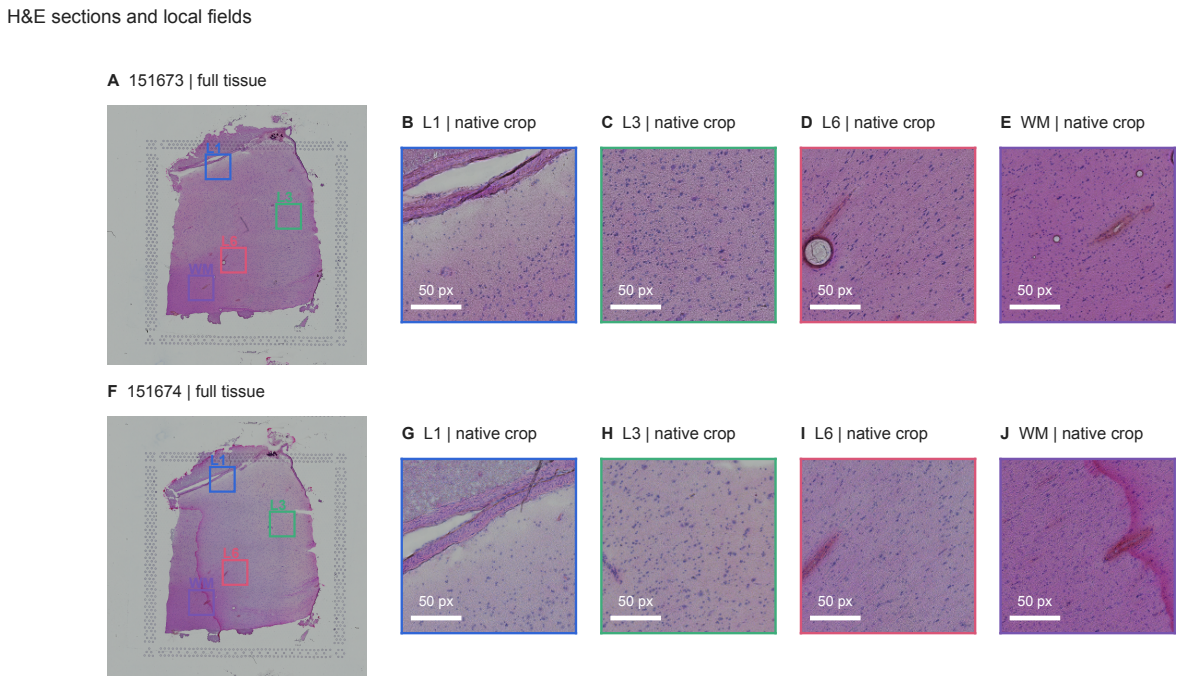

图 16: H&E 整体与局部视野。A、F：两片组织图与取景框。B–E、G–J：L1、L3、L6 和 WM 的 190 × 190 原生像素裁剪；白色标尺为 50 图像像素。取景中心由各参考层坐标确定。

8.2 跨切片层表达一致性

直接相关两组平均表达，可能主要反映普遍高表达基因，而不能突出层特征。为此，对原开发切片选出的 2,000 个高变基因，分别计算每个层相对于其余分析点的平均对数表达差：

$$\Delta_{sgk} = \overline{x}_{s,g,\,y=k} - \overline{x}_{s,g,\,y\neq k}, \tag{7}$$

其中 s 为切片，g 为基因，k 为参考层。随后将开发切片每一层的 2,000 维对比向量与留出切片各层向量做 Spearman 相关，得到 7×7 的对应矩阵。特征集合固定为开发片所选基因。

图17显示，七类中有六类与留出片同名层的相关性最高。WM 的同层相关为 0.916，L3 为 0.819，L1 为 0.709；L6 仅为 0.296。L4 的同层相关为 0.575，而它与留出片 L3 的相关约为 0.591，略高于同名匹配。这与分类器较难识别 L4 的现象相呼应，两项分析均基于同一参考分层。

L6 的弱相关提示，局部取样与层边界的变化可能影响跨片表达对比。层厚度、细胞混合及注释位置均是可能因素，现有双切片数据尚难区分其贡献。WM 则同时具有较高的相关和较宽的基因效应范围，与其较好的分类表现一致。

表 8: 同名层的跨切片表达模式相关性。符号一致率指两片层对比值同号的基因比例；均基于开发片选出的 2,000 个基因。

参考层	同名层相关	符号一致率	留出片最佳匹配
L1	0.709	70.6%	L1
L2	0.646	69.8%	L2
L3	0.819	84.9%	L3
L4	0.575	70.5%	L3
L5	0.662	73.0%	L5
L6	0.296	59.9%	L6
WM	0.916	87.2%	WM

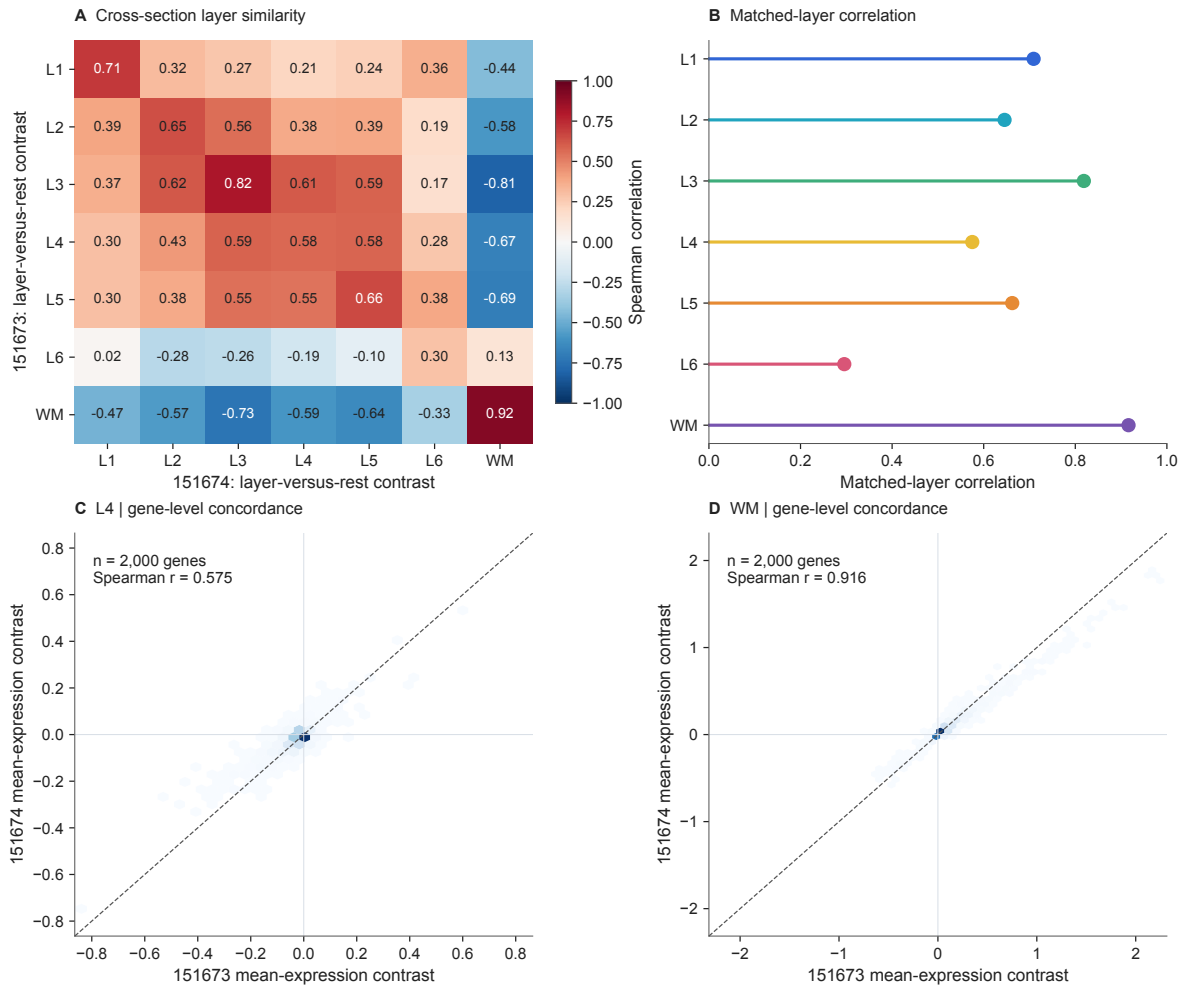

图 17: 跨片层表达对比。A：2,000 维层对比向量的 Spearman 相关矩阵。B：同名层相关。C、D：L4 与 WM 的逐基因对比值；六边形颜色为基因数，虚线为两片对比值相等的位置。

8.3 候选基因发现与方向复核

除事先指定的 12 个标志基因外，本次增加从数据出发的候选基因筛选。只在开发片的 2,000 个高变基因内，按层进行一对其余点的双侧 Mann–Whitney 检验，并在每层的 2,000 次检验中应用 Benjamini–Hochberg 校正。另保存排序 AUC $= U/(n_k n_{\neg k})$、层内检测比例和平均对数表达差。考虑到捕获点存在空间相关，这些 p 值与 q 值仅作为探索性筛选记录；它们没有实现供体层面的错误率控制。

展示面板按开发片平均表达差从高到低选择每层三个候选，要求层内至少 10% 的点检出、对比值为正，且同一基因不在前面层重复入选。顺序固定为 L1–L6、WM。最终 21 个候选全部在留出片保持正方向。复核标准为对比值保持正方向，未要求留出片再次达到点级显著性。

图18将候选基因在两张切片七类区域中的平均表达和检测比例放在一起。CNP、CRYAB、TF 在本次 WM 对比中有较大的正效应；PCP4 在 L5 的平均对数表达差由开发片 0.902 变为留出片 0.823。与此同时，筛选也给出 SCGB2A2、KRT17、SCGB1D2 等需要谨慎核查的 L6 候选。单凭本次排序，不能将它们命名为典型皮层神经元标志；它们可能反映局部组织成分、非目标信号或其他技术因素，具体原因尚未确定。

白质候选与预设 MBP、MOBP 的空间分布相符；L6 候选则需要结合原始比对、独立图谱及原位检测复核。

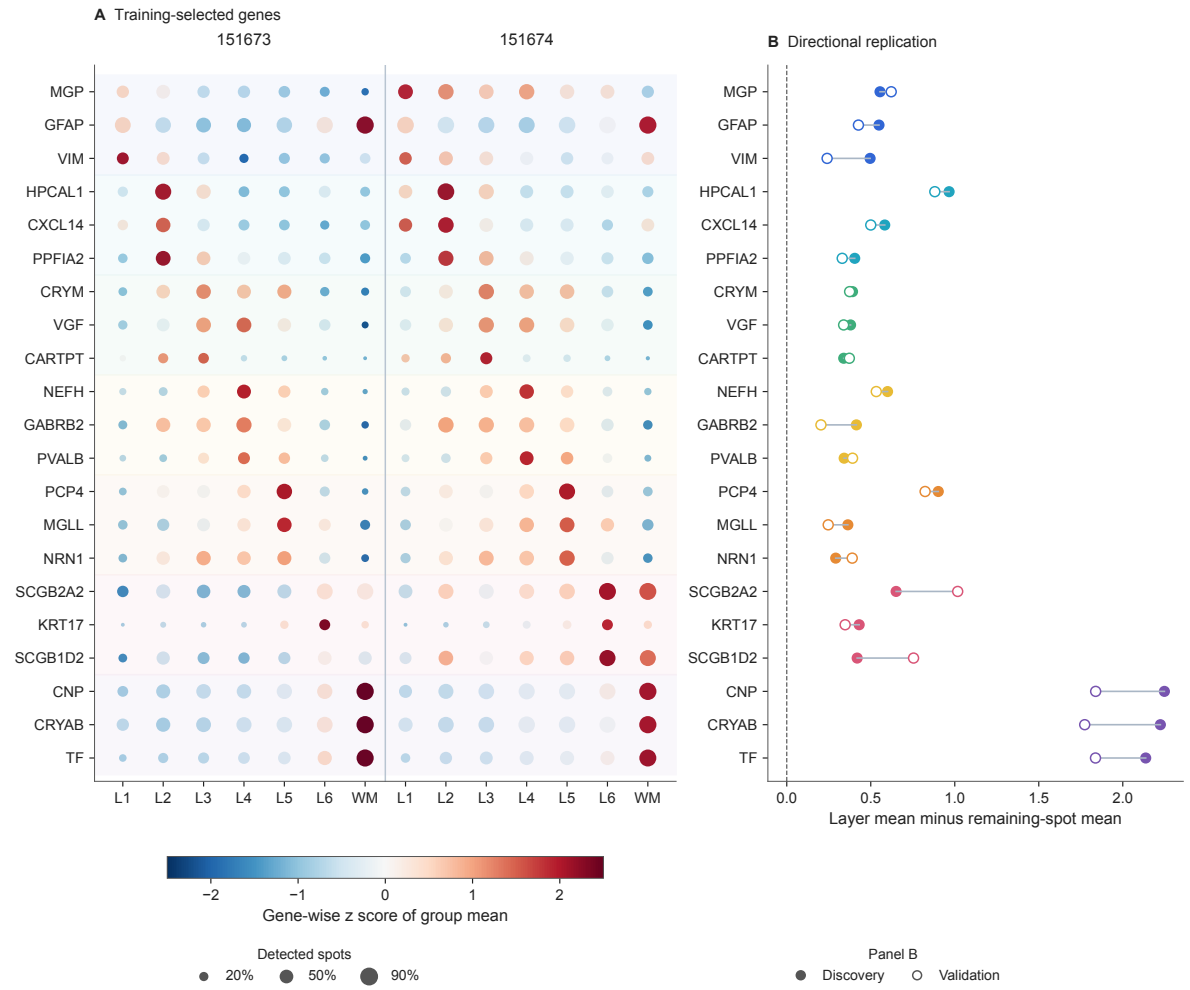

图 18: 开发片筛选的 21 个候选基因。A：两片各层的平均表达与检出率；颜色为每个基因在 14 组均值间的标准化值，点面积表示检出比例。B：实心、空心点分别表示开发片与留出片的层均值减其余点均值。

9　扩展分析二：连续梯度、邻域结构与聚类稳定性

9.1　参考分层引导的几何深度曲线

离散层标签方便建模，却会压缩连续的空间变化。为补充观察，对每张切片以 L1 点的平均坐标指向 WM 点的平均坐标建立单位方向向量 $\boldsymbol{u}_s$，将各点位置投影为 $t_i = \boldsymbol{x}_i^{\mathsf{T}} \boldsymbol{u}_s$。再以投影的第 2 和第 98 百分位作线性缩放，并把超出范围的值截断到 $[0, 1]$。这是一种参考标签引导的几何坐标，近似描述由表浅区域到白质的方向；它不追踪细胞发育，也不提供独立于注释的皮层深度真值。

将该坐标分为 20 个等宽区间，计算预设基因在各区间的平均对数表达。图19显示 CUX2 大体随深度下降，RORB 在中间区域形成较宽的峰，MBP 向白质方向逐渐升高。两张曲线具有相似的总体形状，但局部峰值与起伏不同。这比只报告七个层均值更容易看出，表达变化并不总在人工层边界处突变。

该投影还存在明确的几何限制。真实皮层有弯曲，单一方向不能描述每一点沿局部组织法线的深度；不同层的投影四分位区间因而可能重叠。曲线也会受到各区间点数和组织混合影响。本报告保留每个区间的点数与表达均值供复查，不把曲线的细小波动解释为新的解剖亚层；几何坐标未输入任何预测模型。

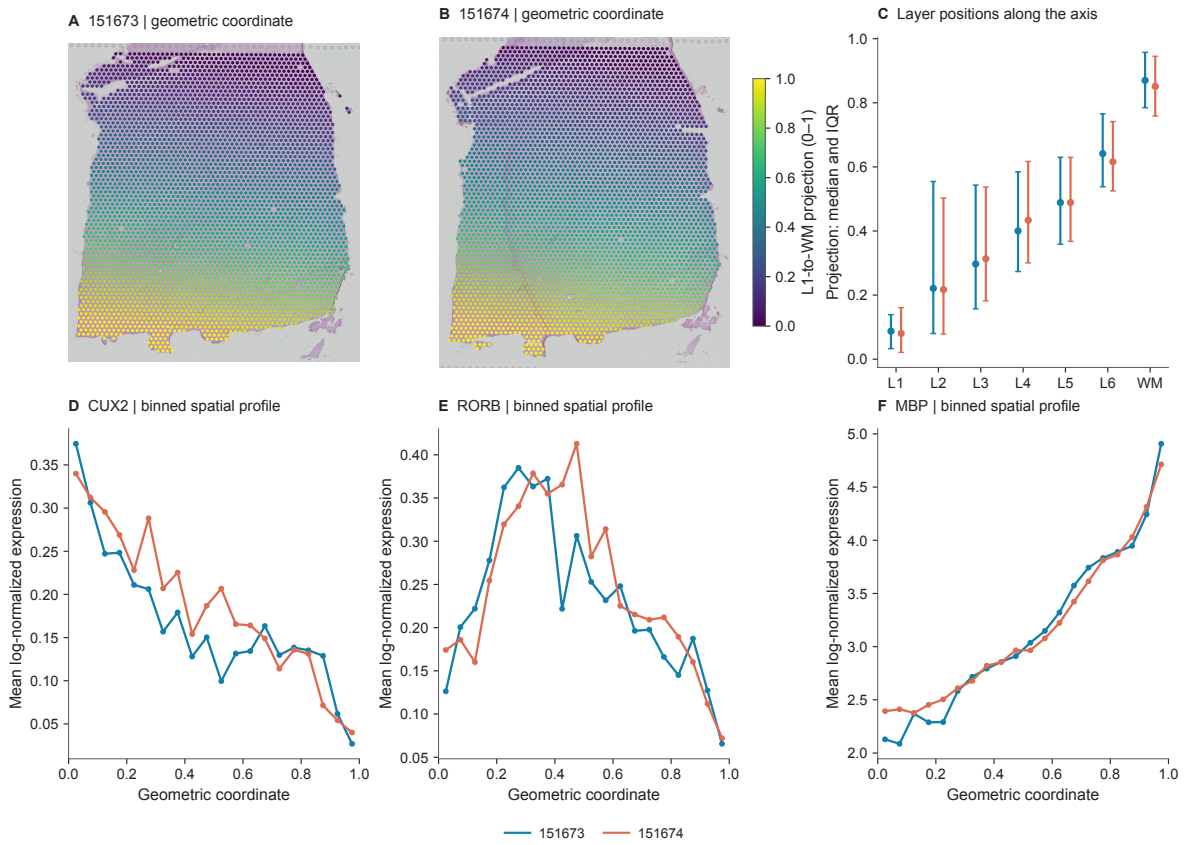

图 19: 几何深度与表达梯度。A、B：以参考标签确定方向的 L1–WM 几何投影。C：各层投影中位数及四分位区间。D–F：20 个等宽区间内 CUX2、RORB、MBP 的平均表达，颜色区分切片。

9.2 参考层邻域接触与置换基准

空间分层还可以作为一张图来检查：点为节点，距离不超过最近点间距中位数的 1.15 倍时连接为邻居。在开发片和留出片分别得到 10,465 与 10,555 条无向边，其中同层边比例为 90.52% 与 90.49%。所有观察到的跨层边都连接顺序相邻的层，说明当前参考标签在图上基本呈连续带状排列。

为区分层大小与接触数量，固定邻接图，随机打乱全部节点的参考层标签 499 次，每次保留各层总体数量。对层 a, b 的接触数，以

$$E_{ab} = \log_2 \frac{O_{ab} + 0.5}{\mathrm{mean}(O_{ab}^{\mathrm{perm}}) + 0.5} \tag{8}$$

描述相对于随机基准的富集，0.5 为处理零计数的伪计数。图20的对角线表现为同层接触富集，远隔层接触缺失；下方网络省略自环，突出跨层接触的链式关系。

全局置换保留各层数量，却破坏了局部空间连续性，因此富集主要反映参考标签的带状分布。Zhang 等的全脑图谱分析还考虑了局部空间背景 [24]。本次邻域以捕获点为单位，接触数仅描述空间相邻关系。

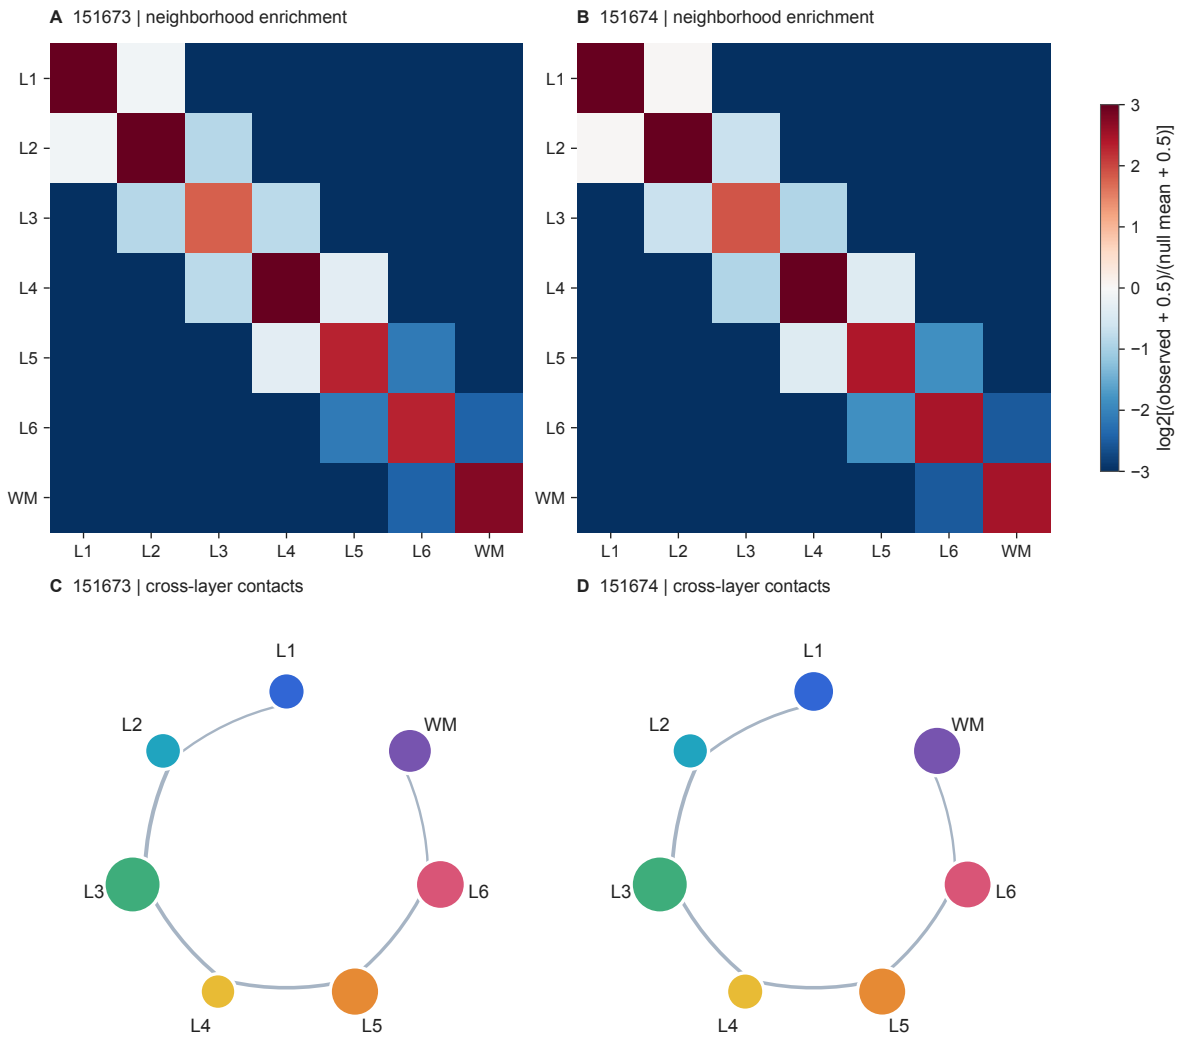

图 20: 参考层邻域结构。A、B：相对 499 次全局标签置换的接触富集，色阶截断于 $[-3, 3]$。C、D：跨层接触网络，节点面积表示层点数，边宽表示接触数；省略同层自环，圆周位置为示意布局。

9.3 空间自相关的多尺度敏感性

单一邻域半径只能描述一个空间尺度。本文进一步把图半径设为最近点间距的 1.15、2.1、3.1、4.1 和 6.1 倍，在两片上分别重算 12 个标志基因的 Moran's I。半径越大，参与比较的空间范围越宽。此处比较统计量随半径的变化，不再进行显著性检验。

图21显示，MBP、MOBP、PLP1 和 GFAP 在多个半径下维持较明显的空间结构，而部分基因的 I 较低。以白质相关表达为例，大区域内相邻位置共享较高表达，即使扩大邻域，空间相似性仍可能存在；较窄的表达带则容易在扩大邻域后与周围不同表达区域混合。曲线可辅助区分宽区域模式与局部变化。

邻域半径、边界截断和测序噪声都会影响 Moran's I。两片使用相同的"点间距倍数"便于比较，却不使它成为跨平台可直接比较的绝对尺度。原始空间表达图、热图和多尺度曲线需要共同阅读：数值较高支持空间聚集，具体聚集在哪里仍需回到组织图确认。

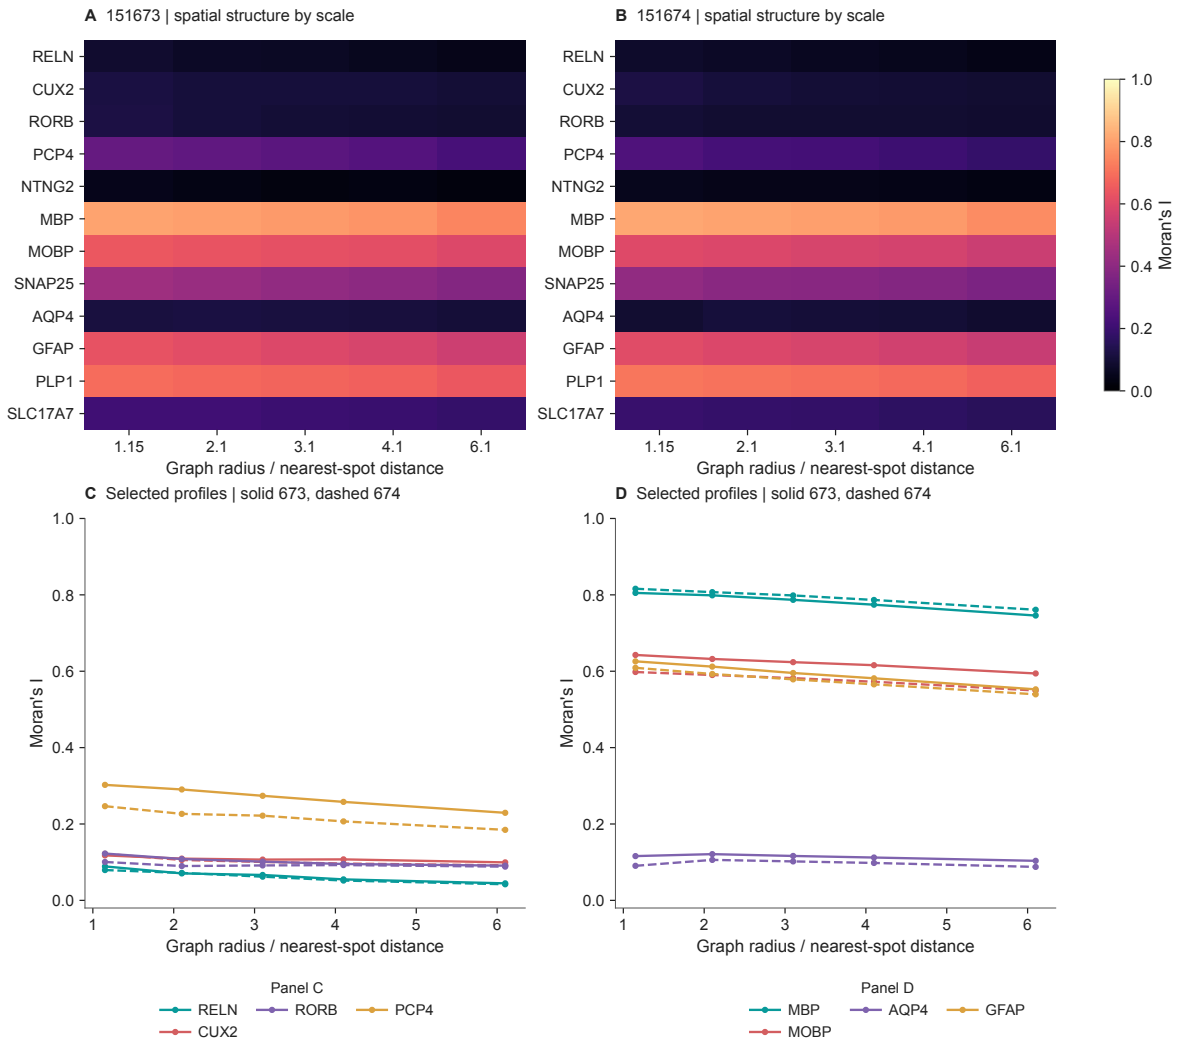

图 21: 多尺度空间自相关。A、B：12 个预设基因在五种邻域半径下的 Moran's I，共享色阶。C、D：八个基因的尺度曲线；实线表示 151673，虚线表示 151674。

9.4 聚类对随机初始化的敏感性

原聚类结果来自固定随机种子。为检查随机性影响，在开发片上令表达表示为 Z、行归一化邻接矩阵为 $\widetilde{W}$，考察

$$Z_\alpha = (1-\alpha)Z + \alpha\widetilde{W}Z, \qquad \alpha \in \{0, 0.25, 0.5, 0.75, 1\}. \tag{9}$$

每个权重用八个固定随机种子运行七簇 K-means，每次设五次初始化；这一计算预算与原主结果的 20 次初始化不同，故作为独立敏感性分析记录。输出两类指标：与参考层的 ARI，以及同权重不同随机种子之间的两两 ARI。后者的 28 个配对共享同一批拟合，不能当作 28 个独立重复。

无平滑时，与参考层的 ARI 中位数为 0.166，随机种子间 ARI 中位数为 0.834；权重 0.5 时分别为 0.224 和 0.970。权重增加到 0.75、1 时，与参考层的一致性中位数继续升高至 0.247、0.248，但随机种子间的一致性下降。这表明增加邻域影响可能改变目标结构和优化结果。主分析仍保留预定的平滑权重。

在固定权重 0.5 下，将八次簇标签通过匈牙利匹配对齐到第一次拟合，逐点计算最常见簇的支持比例。98.1% 的点至少有六次拟合落入同一对齐簇。图22将支持比例放回组织，便于识别对初始化较敏感的位置。该支持比例反映随机初始化的重复性，参考层一致性由 ARI 单独评价。

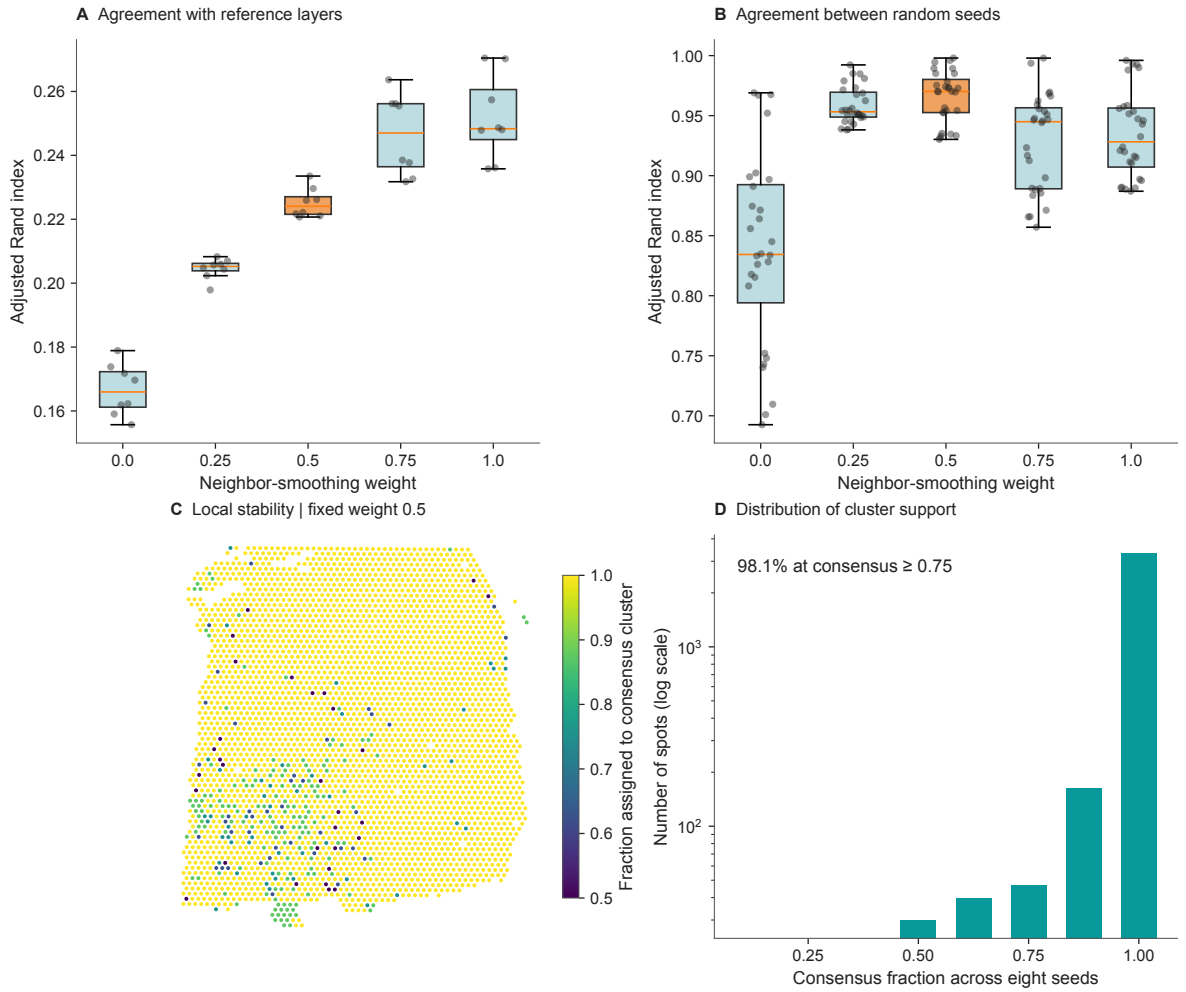

图 22: 平滑权重与随机初始化。A：各权重八次拟合与参考层的 ARI。B：同权重下 28 对拟合之间的 ARI。箱体为四分位区间，中线为中位数；配对值共享拟合。C、D：权重 0.5 下对齐后的逐点支持比例及分布。

10 扩展分析三：错误结构、模型分歧与图像消融

10.1 灰白质分类与精细分层

七分类将不同严重程度的错误合并为一个“不正确”。本报告补充三个任务口径：在全部留出点上判断灰质/白质；在参考标签为 L1–L6 的点上判断精确皮层；以及在同一批皮层点上允许相差一层。最后一项仍把预测为 WM 计为错误，不把白质当作第七个可容许的皮层层次。

逻辑回归的灰白质准确率为 96.70%，但皮层精确准确率为 50.86%；容许相邻一层后为 82.75%。随机森林分别为 97.19%、49.04% 和 74.97%。因此，模型已学到较明显的灰白质区别，而精确相邻层定位仍是主要困难。容许相邻一层的结果作为七分类误差的辅助描述。

10.2 置信度排序与距离边界的错误梯度

按模型最大类别概率从高到低保留部分捕获点，可以得到覆盖率–错误率曲线。逻辑回归保留前约 10% 的 364 个点时错误率为 1.10%，但只覆盖五类参考标签；保留约一半的 1,817 个点时错误率为 26.25%，全部点的错误率为 43.66%。较高置信度对当前样本确实有排序价值，但低错误率部分通过排除困难位置与类别获得。实际应用还需要预先定义允许拒绝哪些样本，并独立评估阈值。

对于空间位置，在原先“邻居中存在不同标签”的边界点集合上，计算其他点到最近边界的最短图距离，分为 0、1、2、至少 3 步。逻辑回归错误率依次为 60.12%、46.17%、42.23%、29.71%。对原空间块进行 500 次重采样所得区间见表9；整体趋势支持模型在层内部相对容易，在边界附近困难。

置信度曲线描述概率排序，边界距离分析提供相应的组织位置解释。二者均为留出片上的事后诊断，未反馈用于训练或阈值选择。

表 9: 留出片中距离参考边界不同的区域及逻辑回归错误率。区间为条件于本切片的空间块 bootstrap 95% 区间。

图距离	点数	错误率	95% 区间
0	1008	60.12%	[55.03%, 65.05%]
1	745	46.17%	[39.21%, 52.29%]
2	618	42.23%	[35.57%, 47.93%]
≥ 3	1262	29.71%	[20.98%, 40.02%]

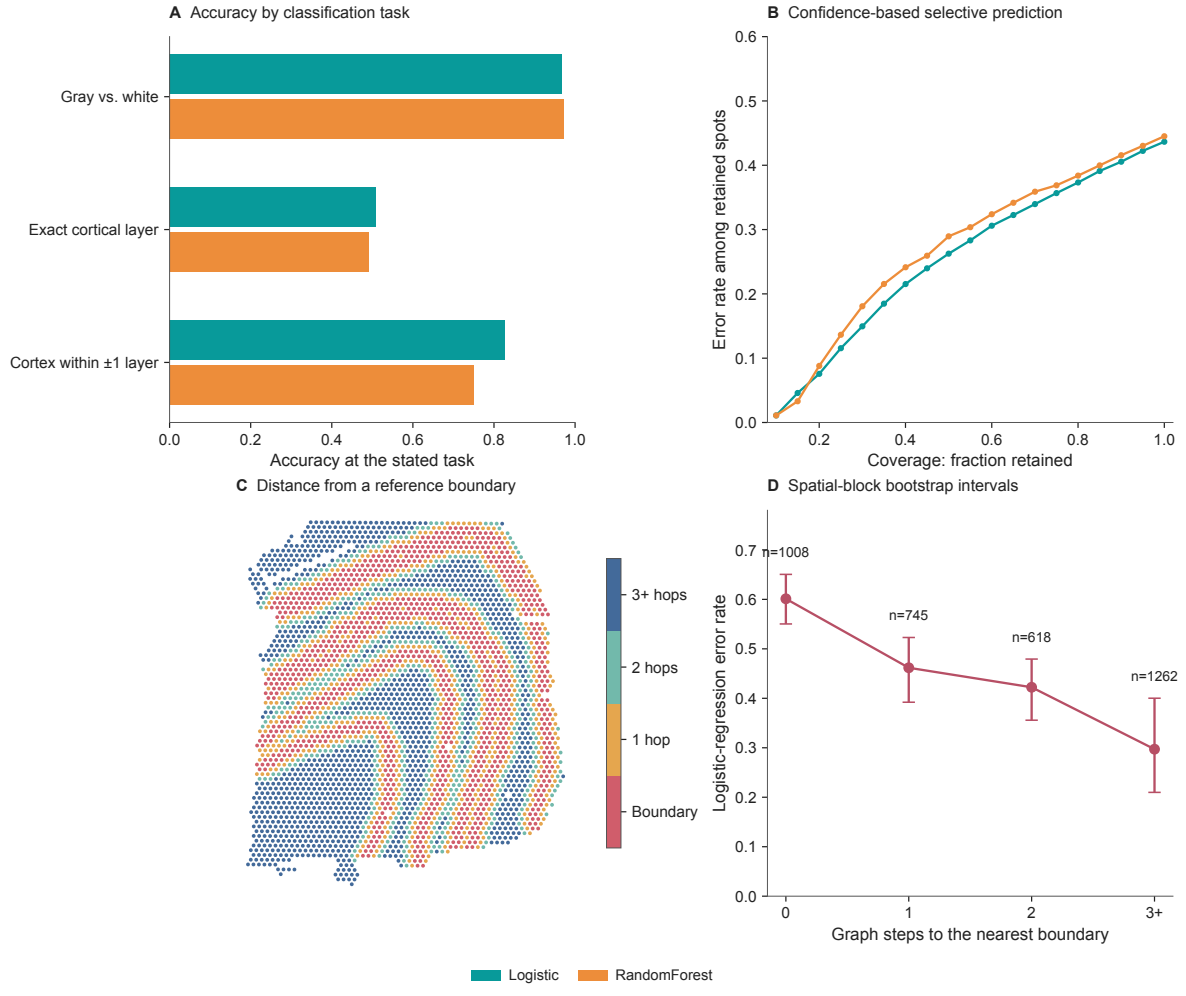

图 23: 分类任务、置信度与边界距离。A：灰白质、精确皮层及容许相邻一层的准确率。B：最大概率排序的覆盖率–错误率曲线。C：至最近参考边界的图距离。D：各距离组错误率及 500 次空间块 bootstrap 95% 区间。

10.3 模型分歧及配对比较

在 3,633 个留出点中，两模型共同正确 1,517 个，仅逻辑回归正确 530 个，仅随机森林正确 499 个，共同错误 1,087 个。两者存在一定互补，但共有误差也占较大比例。

图24同时展示四类正确性组合的组织位置、两模型预测标签之间的混淆、各参考层的组合比例，以及逻辑回归置信度分布。共同错误在部分相邻皮层中占较大比例，而 WM 多为共同正确；这提示两种算法可能受相似的输入信息和标签边界限制。两模型之间的混淆矩阵以逻辑回归预测为行、随机森林预测为列，不能与前文“真值–预测”的混淆矩阵混读。

为使模型比较对应同一批空间区域，以相同的 bootstrap 块索引同时重采样两组预测，再计算宏 F1 之差。随机森林减逻辑回归为 -0.068，95% 区间为 $[-0.104, -0.027]$。在当前切片和固定设置下，差值持续偏向逻辑回归；该条件区间不构成算法在所有供体或数据集上的性能排序。

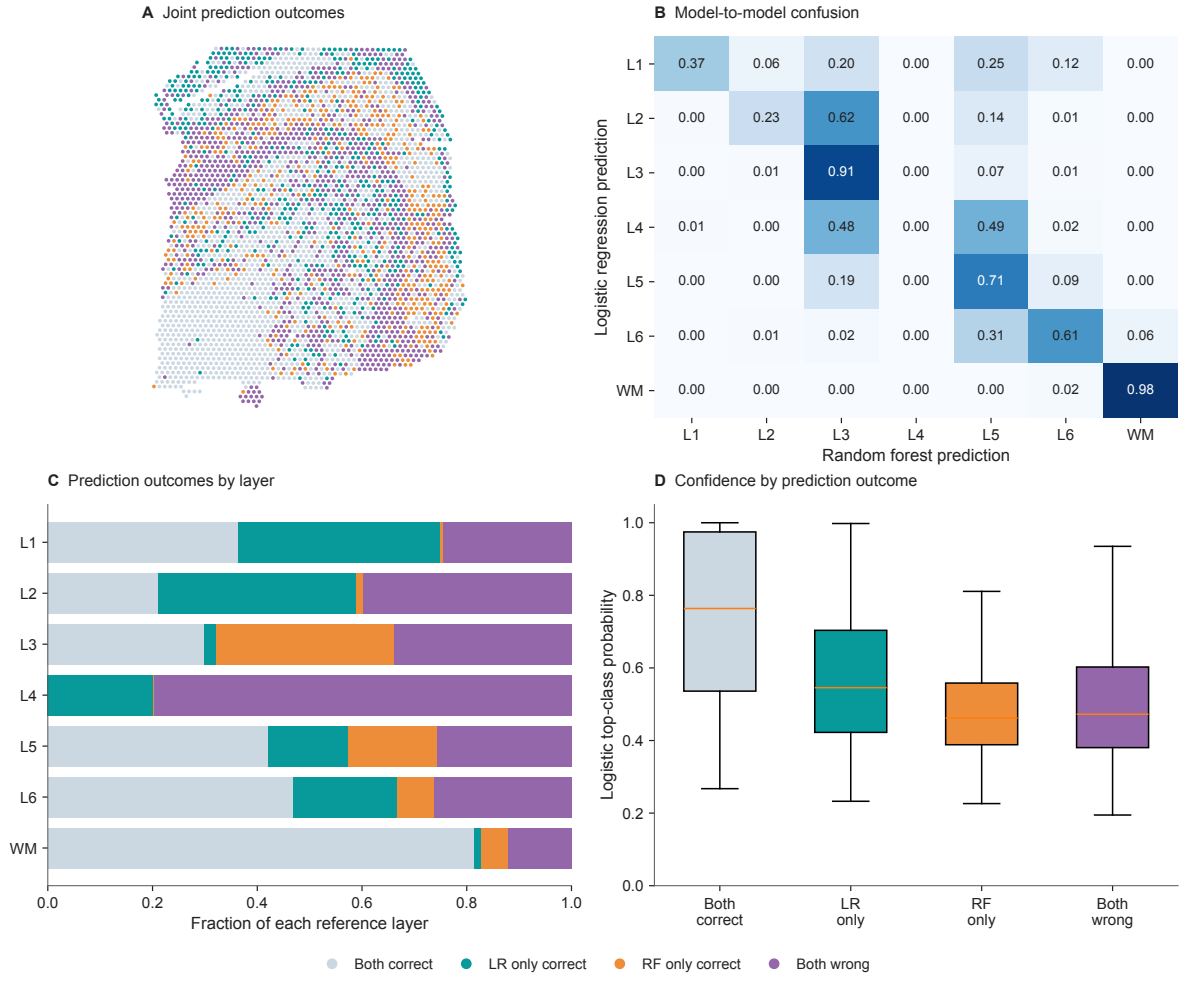

图 24: 两模型的预测分歧。A：按是否正确分组的点位分布。B：模型间行归一化混淆矩阵。C：各参考层的四组比例。D：各组逻辑回归最大概率，箱体为四分位区间，中线为中位数。

10.4 图像特征消融实验

原始组织图除了用于背景叠加，还能转化为数值特征。本文按配准后的点中心裁剪 15×15 hires 像素窗口，其半径由捕获点直径和图像缩放系数计算并取整。每个窗口提取 RGB 三通道均值与标准差、灰度小于 0.65 的像素比例，以及水平和垂直灰度差分平方的平均值，共八个特征。这些量描述局部颜色与简单纹理，不是细胞核数量、染色分离结果或深度病理特征。

全部图像特征的标准化均值和标准差只在开发片拟合。固定使用相同的平衡逻辑回归设置，比较八维图像特征、原 50 维表达主成分，以及 58 维拼接特征。联合模型未使用空间坐标、参考深度或真实留出层标签；没有依据留出片调节图像权重或分类器参数。三种预测均对同一组 3,633 个点进行评价。

表10显示，仅图像、仅表达和联合模型的宏 F1 分别为 0.307、0.536 和 0.518。联合模型相对表达模型的宏 F1 差为 -0.017，配对空间块 bootstrap 95% 区间为 $[-0.057, 0.028]$；当前设置未显示图像拼接的预测增益。

表 10: 相同留出片上的模态对照。表达与联合模型均使用开发片拟合的同一组表达主成分。

输入	准确率	宏 F1	宏 AUROC
仅图像（8 维）	0.368	0.307	0.748
仅表达（50 维）	0.563	0.536	0.896
表达 + 图像（58 维）	0.530	0.518	0.882

图25的图像特征热图还表明，不同层与不同切片的简单颜色特征存在变化。较弱的跨片表现可能与特征过于粗糙、图像缩小、局部血管或染色差异有关，但本次未单独操纵这些因素，无法作出原因归因。SpaGCN 等方法采用更复杂的空间和图像整合机制 [8]。后续可在开发数据内比较染色处理、窗口尺度和融合权重，再以新供体检验增益。

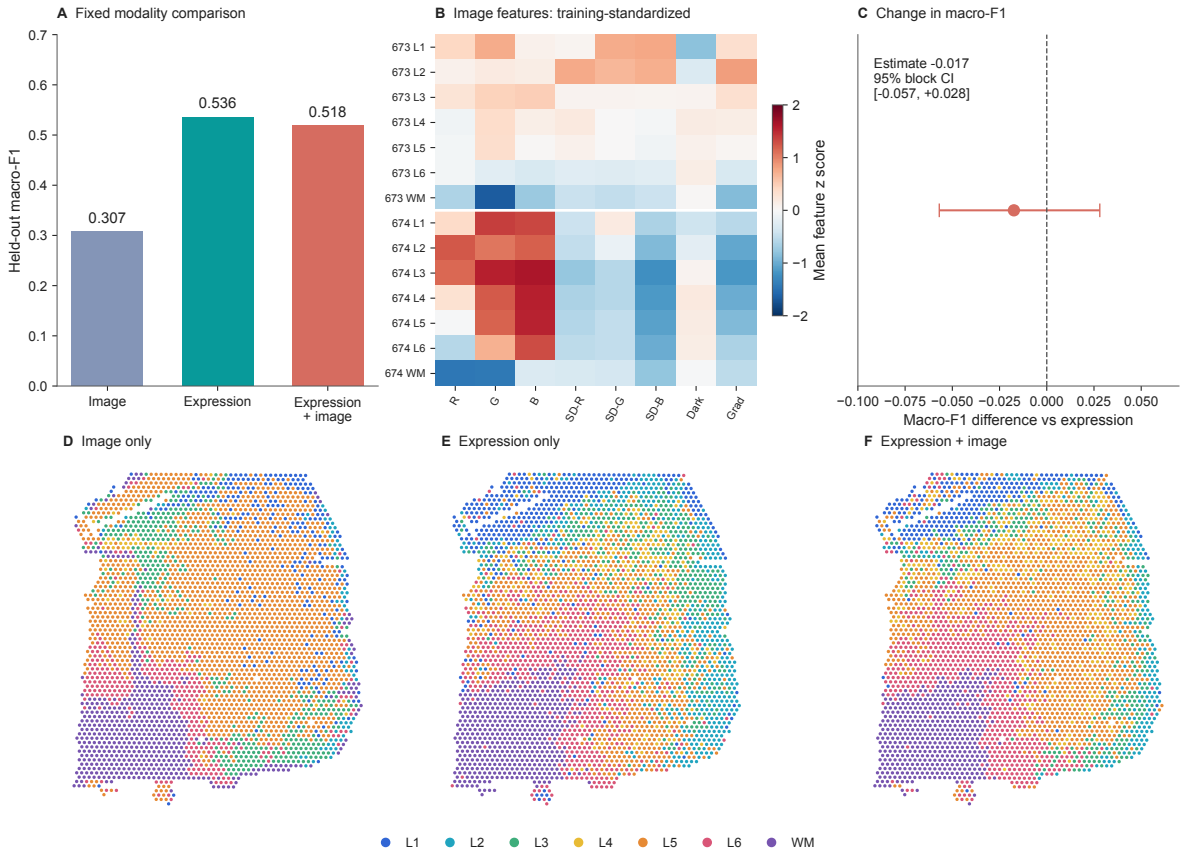

图 25: 图像特征消融。A：三种输入的跨片宏 F1。B：以训练参数标准化的各层图像特征均值。C：联合模型相对表达模型的宏 F1 差及 500 次配对空间块 bootstrap 95% 区间。D–F：三种输入的预测分布。

11 项目展示网页与可复现交付

11.1 交互切片查看器

项目网页包含数据概况、交互切片查看器、模型结果、图版画廊、文献和报告下载。查看器支持切换两张切片，以及 H&E、参考层、基因表达和预测诊断图层；可调整透明度，并查看单个捕获点的数值，便于在同一位置比较形态与表达。

网页展示的是本次已计算的数据，模型不在浏览器中重新训练。静态 JSON、PNG 与 HTML/JavaScript 可离线打开，亦可在普通静态服务器上运行；页面对移动屏幕作了布局适配。实际切片、参考层和预测数据来自同一份派生表，从而减少网页与 PDF 之间的口径差异。项目页源文件随作业打包，独立个人主页网址见第一部分。

项目页入口： `https://ccipad123.github.io/spatial-transcriptomics/`

项目由独立的GitHub 源码仓库托管，支持切片与基因切换、图版查看、结果表和报告下载；无需登录即可访问。离线版本位于 `site/dist/index.html`，个人主页见第一部分。

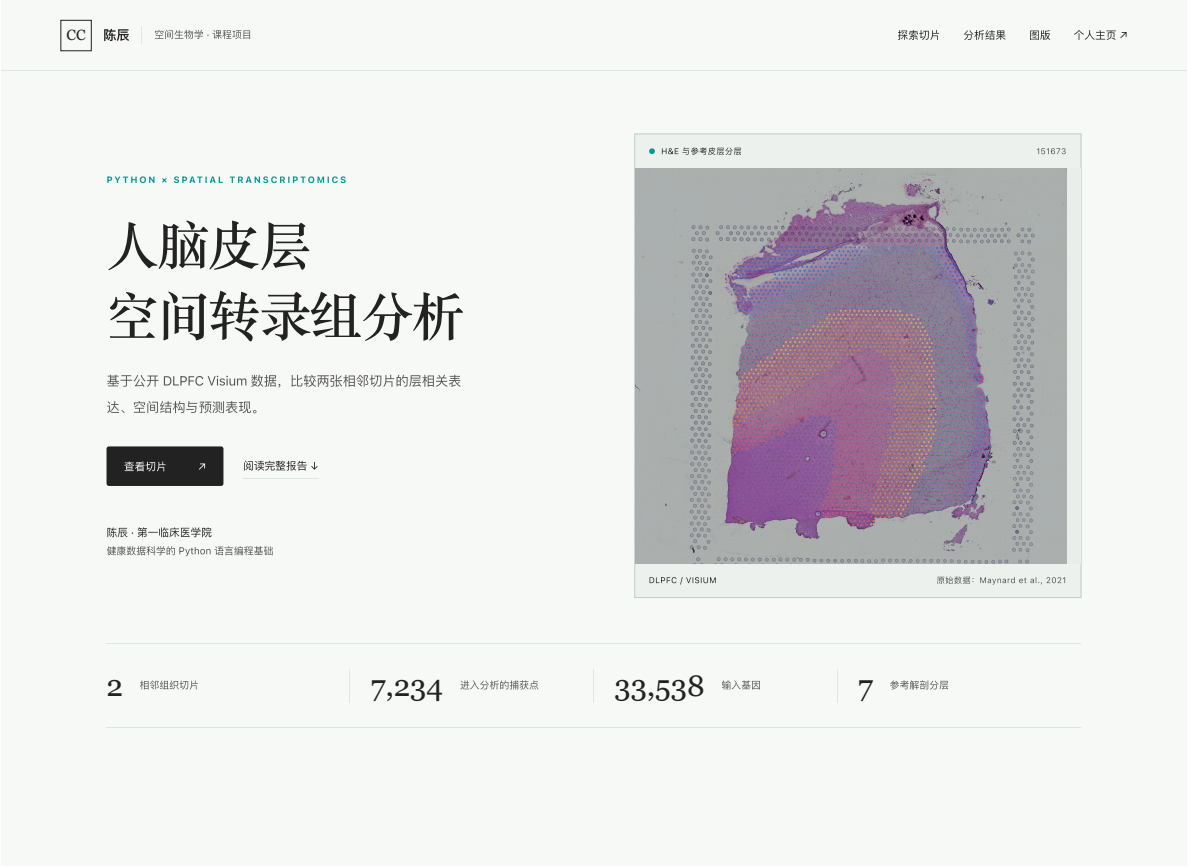

图 26: 项目网页首页，采用浏览器矢量打印；文字与分层散点为矢量对象，H&E 底图保留原始像素。

11.2 文件组织与复现实验

主流程随机种子为 20261012，扩展分析的置换与重采样种子为 20261112。图表由保存的结果文件生成，组织底图取自作者公开数据。数据清单、软件版本、运行日志与文献核验记录均随源文件提供。

表 11: 交付目录与用途

文件或目录	内容
`report/main.tex` 与 `refs.bib`	指定模板改写的正文与核验后的参考文献
`report/generated/`	从结果表自动生成的数字、表格和代码节选
`src/download_data.py`	小规模公开数据下载与校验记录
`src/analyze.py`	从稀疏计数到统计与预测的主流程
`src/make_figures.py`	原 15 组图版的可复现绘制
`src/extended_analysis.py`	跨片一致性、邻域、稳定性和图像消融
`src/extended_figures.py`	新增 10 组多面板分析图
`data/raw/` 与 `data/derived/`	原始下载文件及中间派生数据
`results/` 与 `logs/`	数值结果、文献元数据、运行记录
`site/dist/`	可交互展示页与静态资源
`requirements-lock.txt`	本次运行的软件版本记录
`output/pdf/`	使用 XeLaTeX 编译的最终 PDF

运行时先核对数据清单和软件环境，再依次执行分析、绘图、结果表生成及网页生成，最后用 XeLaTeX–BibTeX–XeLaTeX–XeLaTeX 编译报告。本地独立环境复用现有基础科学计算包，新安装的 h5py、matplotlib 和 statsmodels 位于作业环境内；实际版本由运行程序写入结果摘要。附录摘录主脚本的核心部分，完整代码以源文件为准。

12 讨论

12.1 空间结构与预测表现

两张切片呈现相近的层相关表达，其中白质信号最为清楚。MBP 的层间效应量和 Moran's I 均较高，WM 表达对比的跨片相关达到 0.916，逻辑回归对 WM 的 F1 为 0.896。空间分布、表达对比与分类结果在这一组织区域相互吻合。

相邻皮层的情况较复杂。L4 与留出片 L3 的表达对比相关略高于同名层，其分类 F1 也最低。邻域平滑提高了聚类 ARI，但平滑后的 ARI 仍约为 0.222。局部表达连续性有助于形成连贯区域，却不足以恢复全部参考边界；过强的平滑还可能合并较薄的层。

逻辑回归的宏 AUROC 接近 0.90，宏 F1 却仅为 0.54。这一差异与多分类决策有关：某层相对其余层的概率排序可以较好，但相邻层之间的最大概率仍容易发生交换。边界点较高的错误率和 L2、L3 不对称的精确率与召回率，进一步表明误差具有明确的层次和位置分布。

12.2 跨片一致性与图像消融

跨片相关并非所有层都同样高。L6 的相关仅为 0.296，且其候选面板出现 SCGB2A2、KRT17、SCGB1D2 等需复核的基因。21 个候选在留出片方向一致，支持该局部组织的重复性，但不足以确立层特异标志。几何深度曲线和多尺度自相关则补充了分层均值之外的信息，显示表达变化既包含宽区域差异，也包含连续梯度。

聚类的种子间一致性较高，而其与参考层的 ARI 较低，说明算法稳定性和解剖一致性需要分别评价。图像消融也给出类似的启示：八个颜色与纹理特征未改善跨片预测。当前特征可能不足以捕捉与分层有关的形态，或受切片间染色差异影响；现有实验尚不能区分这两种解释。

12.3 主要局限

样本的主要限制是生物学重复不足。两张相邻切片只代表一名供体，捕获点数再多也不能替代独立供体数。点级检验、网格稳健标准误和块 bootstrap 都不能把样本设计升级为人群研究。更可靠的后续方案是增加不同供体，在外层按供体留出，在内层选择特征与参数。

参考标签也具有不确定性。分层注释利用组织形态与表达证据，标签边界也存在不确定性。模型学习表达后与这些标签一致，既可能体现合理生物结构，也可能部分复现注释所依据的信息。理想评估应增加独立病理复核或原位验证，并考虑模糊边界标签。

Visium 点位覆盖的局部区域可包含多个细胞或神经纤维等结构。缺失计数不等于生物学绝对不表达；标准化也不能消除所有组织处理与测量差异。单基因空间图应与多基因模式共同解释。

验证仍受空间相关影响。网格块之间没有缓冲，且相邻切片高度相关。这里的空间块方案是课程层面的改进示例，不是彻底消除相关性的保证。需要对块尺寸、相关距离和测试目标进行进一步预设与敏感性分析。

模型比较范围有限。本项目固定轻量参数，没有全面搜索，也没有复现图神经网络、反卷积或专门的多模态整合算法；新增联合模型仅拼接简单特征。因此“逻辑回归优于随机森林”只适用于本次特征与切分设置，不能推广为算法的一般排序。

12.4 后续研究

后续工作可先扩展到原资源全部切片，建立供体留出评估；随后在同一数据划分和评价口径下复现一种空间模型，检验复杂方法是否带来稳定增益。若引入匹配单细胞参考，可进一步估计细胞类型组成，但要报告参考依赖和未识别细胞类型的影响。本次简单图像消融未见增益，后续可用开发集预先评价染色标准化、细胞核分割或更合适的窗口尺度，再在新供体上检验；不应继续依赖本次已经查看过的留出切片决定图像方案。

13　结论

本次复分析将公开 DLPFC 相邻切片的基因计数、组织图、空间坐标与参考分层按捕获点对应起来，在 7312 个输入点中纳入 7234 个合格点，完成了从数据核对到空间统计、预测评估和网页展示的分析。两张切片来自同一供体，因此本研究回答的是局部组织中表达模式的跨片重复性及模型的跨片迁移表现，尚不能据此判断不同供体之间的适用性。

空间表达分析显示，白质与皮层的差异比相邻皮层之间的差异更清楚。白质的层表达对比在两片间相关达到 0.916；七类区域中，六类与另一片同名区域的相关性最高，开发片选出的 21 个候选基因在留出片均保持正方向。这些结果相互支持，但候选基因的方向一致还不足以确立其层特异性。邻域平滑将聚类 ARI 从 0.174 提高到 0.222，说明局部空间信息有助于恢复连贯的表达区域；平滑后的聚类与参考分层仍有明显差距，算法输出稳定也不等于解剖边界准确。

在固定开发片与留出片的预测设置下，逻辑回归取得宏 F1 为 0.536、宏 AUROC 为 0.896 的结果，宏 F1 高于本次随机森林的 0.468。白质 F1 为 0.896，而错误更多发生于相邻皮层，参考边界点的错误率为 60.1%，高于内部点的 37.3%。因此，单一平均指标不足以描述分层质量，还需结合混淆矩阵、概率校准和误差的组织位置。加入八维颜色与纹理特征后，宏 F1 为 0.518，联合模型相对表达模型的配对区间包含零；本次实验未见明确增益，这一判断仅针对所选图像特征与拼接方式。

本报告的主要收获是将数据读取、训练集内预处理、空间结构分析和留出切片评估落实到同一套可核查流程中。保存的预测表、统计结果、矢量图和代码支持追溯主要结论，交互网页则用于检查局部表达与预测位置。进一步提高分析可信度，应优先增加独立供体、采用供体留出验证，并在开发数据内确定空间邻域和图像特征方案；对薄层及边界区域，还需结合独立的组织学复核。现有结果为后续空间模型和多模态方法提供了可比较的基线，也明确了当前数据规模和验证设计所能支持的结论范围。

参考文献

[1] Ståhl P. L., Salmén F., Vickovic S., et al. Visualization and analysis of gene expression in tissue sections by spatial transcriptomics[J/OL]. Science, 2016, 353(6294):78-82. https://doi.org/10.1126/science.aaf2403.

[2] Rao A., Barkley D., França G. S., et al. Exploring tissue architecture using spatial transcriptomics [J/OL]. Nature, 2021, 596(7871):211-220. https://doi.org/10.1038/s41586-021-03634-9.

[3] Moses L., Pachter L. Museum of spatial transcriptomics[J/OL]. Nature Methods, 2022, 19(5):534-546. https://doi.org/10.1038/s41592-022-01409-2.

[4] Maynard K. R., Collado-Torres L., Weber L. M., et al. Transcriptome-scale spatial gene expression in the human dorsolateral prefrontal cortex[J/OL]. Nature Neuroscience, 2021, 24(3):425-436. https://doi.org/10.1038/s41593-020-00787-0.

[5] Wolf F. A., Angerer P., Theis F. J. SCANPY: large-scale single-cell gene expression data analysis[J/OL]. Genome Biology, 2018, 19(1):15. https://doi.org/10.1186/s13059-017-1382-0.

[6] Palla G., Spitzer H., Klein M., et al. Squidpy: a scalable framework for spatial omics analysis[J/OL]. Nature Methods, 2022, 19(2):171-178. https://doi.org/10.1038/s41592-021-01358-2.

[7] Zhao E., Stone M. R., Ren X., et al. Spatial transcriptomics at subspot resolution with BayesSpace [J/OL]. Nature Biotechnology, 2021, 39(11):1375-1384. https://doi.org/10.1038/s41587-021-00935-2.

[8] Hu J., Li X., Coleman K., et al. SpaGCN: Integrating gene expression, spatial location and histology to identify spatial domains and spatially variable genes by graph convolutional network[J/OL]. Nature Methods, 2021, 18(11):1342-1351. https://doi.org/10.1038/s41592-021-01255-8.

[9] Dong K., Zhang S. Deciphering spatial domains from spatially resolved transcriptomics with an adaptive graph attention auto-encoder[J/OL]. Nature Communications, 2022, 13(1):1739. https://doi.org/10.1038/s41467-022-29439-6.

[10] Xu H., Fu H., Long Y., et al. Unsupervised spatially embedded deep representation of spatial transcriptomics[J/OL]. Genome Medicine, 2024, 16(1):12. https://doi.org/10.1186/s13073-024-01283-x.

[11] Pardo B., Spangler A., Weber L. M., et al. spatialLIBD: an R/Bioconductor package to visualize spatially-resolved transcriptomics data[J/OL]. BMC Genomics, 2022, 23(1):434. https://doi.org/10.1186/s12864-022-08601-w.

[12] Longo S. K., Guo M. G., Ji A. L., et al. Integrating single-cell and spatial transcriptomics to elucidate intercellular tissue dynamics[J/OL]. Nature Reviews Genetics, 2021, 22(10):627-644. https://doi.org/10.1038/s41576-021-00370-8.

[13] Kleshchevnikov V., Shmatko A., Dann E., et al. Cell2location maps fine-grained cell types in spatial transcriptomics[J/OL]. Nature Biotechnology, 2022, 40(5):661-671. https://doi.org/10.1038/s41587-021-01139-4.

[14] Lohoff T., Ghazanfar S., Missarova A., et al. Integration of spatial and single-cell transcriptomic data elucidates mouse organogenesis[J/OL]. Nature Biotechnology, 2022, 40(1):74-85. https://doi.org/10.1038/s41587-021-01006-2.

[15] Huuki-Myers L. A., Spangler A., Eagles N. J., et al. A data-driven single-cell and spatial transcriptomic map of the human prefrontal cortex[J/OL]. Science, 2024, 384(6698):eadh1938. https://doi.org/10.1126/science.adh1938.

[16] Rodriques S. G., Stickels R. R., Goeva A., et al. Slide-seq: A scalable technology for measuring genome-wide expression at high spatial resolution[J/OL]. Science, 2019, 363(6434):1463-1467. https://doi.org/10.1126/science.aaw1219.

[17] Stickels R. R., Murray E., Kumar P., et al. Highly sensitive spatial transcriptomics at near-cellular resolution with Slide-seqV2[J/OL]. Nature Biotechnology, 2021, 39(3):313-319. https://doi.org/10.1038/s41587-020-0739-1.

[18] Vickovic S., Eraslan G., Salmén F., et al. High-definition spatial transcriptomics for in situ tissue profiling[J/OL]. Nature Methods, 2019, 16(10):987-990. https://doi.org/10.1038/s41592-019-0548-y.

[19] Chen A., Liao S., Cheng M., et al. Spatiotemporal transcriptomic atlas of mouse organogenesis using DNA nanoball-patterned arrays[J/OL]. Cell, 2022, 185(10):1777-1792.e21. https://doi.org/10.1016/j.cell.2022.04.003.

[20] Chen K. H., Boettiger A. N., Moffitt J. R., et al. Spatially resolved, highly multiplexed RNA profiling in single cells[J/OL]. Science, 2015, 348(6233):aaa6090. https://doi.org/10.1126/science.aaa6090.

[21] Eng C.-H. L., Lawson M., Zhu Q., et al. Transcriptome-scale super-resolved imaging in tissues by RNA seqFISH+[J/OL]. Nature, 2019, 568(7751):235-239. https://doi.org/10.1038/s41586-019-1049-y.

[22] Hawrylycz M. J., Lein E. S., Guillozet-Bongaarts A. L., et al. An anatomically comprehensive atlas of the adult human brain transcriptome[J/OL]. Nature, 2012, 489(7416):391-399. https://doi.org/10.1038/nature11405.

[23] Yao Z., van Velthoven C. T. J., Kunst M., et al. A high-resolution transcriptomic and spatial atlas of cell types in the whole mouse brain[J/OL]. Nature, 2023, 624(7991):317-332. https://doi.org/10.1038/s41586-023-06812-z.

[24] Zhang M., Pan X., Jung W., et al. Molecularly defined and spatially resolved cell atlas of the whole mouse brain[J/OL]. Nature, 2023, 624(7991):343-354. https://doi.org/10.1038/s41586-023-06808-9.

[25] Asp M., Giacomello S., Larsson L., et al. A Spatiotemporal Organ-Wide Gene Expression and Cell Atlas of the Developing Human Heart[J/OL]. Cell, 2019, 179(7):1647-1660.e19. https://doi.org/10.1016/j.cell.2019.11.025.

[26] Ji A. L., Rubin A. J., Thrane K., et al. Multimodal Analysis of Composition and Spatial Architecture in Human Squamous Cell Carcinoma[J/OL]. Cell, 2020, 182(2):497-514.e22. https://doi.org/10.1016/j.cell.2020.05.039.

[27] Moncada R., Barkley D., Wagner F., et al. Integrating microarray-based spatial transcriptomics and single-cell RNA-seq reveals tissue architecture in pancreatic ductal adenocarcinomas[J/OL]. Nature Biotechnology, 2020, 38(3):333-342. https://doi.org/10.1038/s41587-019-0392-8.

[28] Cable D. M., Murray E., Zou L. S., et al. Robust decomposition of cell type mixtures in spatial transcriptomics[J/OL]. Nature Biotechnology, 2022, 40(4):517-526. https://doi.org/10.1038/s41587-021-00830-w.

[29] Biancalani T., Scalia G., Buffoni L., et al. Deep learning and alignment of spatially resolved single-cell transcriptomes with Tangram[J/OL]. Nature Methods, 2021, 18(11):1352-1362. https://doi.org/10.1038/s41592-021-01264-7.

[30] Hao Y., Hao S., Andersen-Nissen E., et al. Integrated analysis of multimodal single-cell data[J/OL]. Cell, 2021, 184(13):3573-3587.e29. https://doi.org/10.1016/j.cell.2021.04.048.

[31] Svensson V., Teichmann S. A., Stegle O. SpatialDE: identification of spatially variable genes[J/OL]. Nature Methods, 2018, 15(5):343-346. https://doi.org/10.1038/nmeth.4636.

[32] Edsgärd D., Johnsson P., Sandberg R. Identification of spatial expression trends in single-cell gene expression data[J/OL]. Nature Methods, 2018, 15(5):339-342. https://doi.org/10.1038/nmeth.4634.

[33] Benjamini Y., Hochberg Y. Controlling the False Discovery Rate: A Practical and Powerful Approach to Multiple Testing[J/OL]. Journal of the Royal Statistical Society Series B: Statistical Methodology, 1995, 57(1):289-300. https://doi.org/10.1111/j.2517-6161.1995.tb02031.x.

[34] Breiman L. Random Forests[J/OL]. Machine Learning, 2001, 45(1):5-32. https://doi.org/10.1023/A:1010933404324.

[35] Roberts D. R., Bahn V., Ciuti S., et al. Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure[J/OL]. Ecography, 2017, 40(8):913-929. https://doi.org/10.1111/ecog.02881.

致谢

感谢本课程的授课老师和各位助教老师。每周前三节课的讲授帮助我理解 Python 编程、统计分析和机器学习的基本方法；最后一节助教实践课介绍了数据处理、工具使用和具体操作，对完成这份作业很有帮助。

感谢老师和助教们的耐心讲解与指导，也感谢公开数据和开源工具的研究者。

A 核心代码

以下片段直接从实际运行的 src/analyze.py 提取；路径、依赖导入、常量与完整保存逻辑见完整脚本。片段中的 ROOT 为项目根目录，SEED=20261012，LAYERS 为 L1–L6 与 WM。为保持篇幅，未重复列出绘图和网页代码。

A.1 HDF5 读取、坐标连接与参考标签

```
def read_section(sample):
    d=ROOT/'data/raw'/sample
    with h5py.File(d/'counts.h5','r') as h:
        m=h['matrix']
        X=sparse.csc_matrix((m['data'][:],m['indices'][:],m['indptr'][:]),shape=tuple(m['shape'][:])).T.tocsr().astype(np.float32)
        genes=np.array([x.decode() for x in m['features']['name'][:]])
        ids=np.array([x.decode() for x in m['features']['id'][:]])
        barcodes=[x.decode() for x in m['barcodes'][:]]
    assert len(set(barcodes))==len(barcodes)
    positions=pd.read_csv(d/'tissue_positions_list.csv',header=None,names=['barcode','in_tissue','array_row','array_col','pixel_row
      ','pixel_col']).set_index('barcode')
    assert positions.index.is_unique
    obs=positions.loc[barcodes].copy()
    labels=pd.read_csv(ROOT/'data/raw/barcode_level_layer_map.tsv',sep='\t',header=None,names=['barcode','sample','layer'])
    labels=labels[labels['sample'].astype(str)==sample].set_index('barcode')
    assert labels.index.is_unique
    obs['layer']=labels['layer'].reindex(obs.index)
    meta=pd.read_csv(d/'metadata.tsv',sep='\t',index_col=0)
    assert meta.index.is_unique
    common=obs.index.intersection(meta.index)
    assert (obs.loc[common,'layer'].fillna('NA')==meta.loc[common,'layer_guess_reordered_short'].fillna('NA')).all(), 'Primary/
      mirror label mismatch'
    assert np.allclose(np.asarray(X.sum(1)).ravel(),meta.loc[obs.index,'sum_umi']), 'Count and barcode alignment mismatch'
    scale=json.loads((d/'scalefactors_json.json').read_text())
    obs['x']=obs.pixel_col*scale['tissue_hires_scalef'];obs['y']=obs.pixel_row*scale['tissue_hires_scalef']
    # Independent coordinate cross-check against the mirror's 600px image coordinates.
```

A.2 归一化与只在训练集拟合的预处理器

```
def lognorm(X):
    total=np.asarray(X.sum(1)).ravel()
    Y=sparse.diags(1e4/np.maximum(total,1))@X
    Y=Y.tocsr();Y.data=np.log1p(Y.data)
    return Y

class GeneProjector(BaseEstimator,TransformerMixin):
    """Fit-only-on-training, mean-binned dispersion -> scaling -> 50-PC pipeline."""
    def __init__(self,genes,n_hvg=2000,n_pcs=50):
        self.genes=genes;self.n_hvg=n_hvg;self.n_pcs=n_pcs
    def fit(self,X,y=None):
        mean=np.asarray(X.mean(0)).ravel();var=np.asarray(X.power(2).mean(0)).ravel()-mean**2
        detection=np.asarray((X>0).sum(0)).ravel()
        allowed=(detection>=20)&(~np.char.startswith(self.genes.astype(str),'MT-'))&(~np.char.startswith(self.genes.astype(str),'
      RPL'))&(~np.char.startswith(self.genes.astype(str),'RPS'))
        ix=np.flatnonzero(allowed)
        bins=pd.qcut(mean[ix],20,labels=False,duplicates='drop')
        disp=var[ix]/np.maximum(mean[ix],1e-8)
        score=np.zeros(len(ix))
        for b in np.unique(bins):
            hit=np.asarray(bins==b);score[hit]=(disp[hit]-disp[hit].mean())/max(disp[hit].std(),1e-8)
        self.selected_=ix[np.argsort(score,kind='stable')[-self.n_hvg:]]
        self.scaler_=StandardScaler().fit(X[:,self.selected_].toarray())
        Z=np.clip(self.scaler_.transform(X[:,self.selected_].toarray()),-10,10)
        self.pca_=PCA(n_components=self.n_pcs,svd_solver='randomized',random_state=SEED).fit(Z)
        self.allowed_count_=len(ix)
```

```
        return self
    def transform(self,X):
        Z=np.clip(self.scaler_.transform(X[:,self.selected_].toarray()),-10,10)
        return self.pca_.transform(Z)
```

A.3 邻接图、Moran's I 与置换检验

```
def graph(obs):
    xy=obs[['x','y']].to_numpy()
    tree=cKDTree(xy);dist,_=tree.query(xy,k=2)
    radius=float(np.median(dist[:,1])*1.15)
    pairs=tree.query_pairs(radius,output_type='ndarray')
    row=np.r_[pairs[:,0],pairs[:,1]];col=np.r_[pairs[:,1],pairs[:,0]]
    W=sparse.csr_matrix((np.ones(len(row)),(row,col)),shape=(len(obs),len(obs)))
    return W,radius

def moran(v,W,rng,n_perm=999):
    z=v-v.mean();den=float(z@z)
    if den==0:return np.nan,np.nan
    c=len(v)/W.sum()/den
    observed=float(c*(z@(W@z)))
    sim=np.empty(n_perm)
    for i in range(n_perm):
        zz=rng.permutation(z);sim[i]=c*(zz@(W@zz))
    return observed,float((1+(sim>=observed).sum())/(n_perm+1))
```

A.4 模型参数与评估函数

```
def metrics(y,p,prob):
    Y=label_binarize(y,classes=np.arange(7))
    return {'accuracy':accuracy_score(y,p),'balanced_accuracy':balanced_accuracy_score(y,p),
            'macro_f1':f1_score(y,p,labels=np.arange(7),average='macro',zero_division=0),
            'macro_auroc':roc_auc_score(Y,prob,average='macro'),
            'macro_ap':average_precision_score(Y,prob,average='macro'),
            'log_loss':log_loss(y,prob,labels=np.arange(7)),
            'brier_multiclass':float(np.mean(np.sum((Y-prob)**2,axis=1)))}

def new_models():
    return {'Majority':DummyClassifier(strategy='most_frequent'),
            'Logistic':LogisticRegression(C=1.0,solver='lbfgs',max_iter=2000,class_weight='balanced',random_state=SEED),
            'RandomForest':RandomForestClassifier(n_estimators=300,min_samples_leaf=3,max_features='sqrt',class_weight='
      balanced_subsample',n_jobs=2,random_state=SEED)}
```

A.5 训练/测试分离与实际执行循环

其中 `tr,te` 为分层随机切分索引，`btr,bte` 为空间块切分索引，`a,b` 分别为开发与留出切片。完整脚本包含索引生成和数据断言。

```
scenarios=[('Random within section',tr,te,a,y_a[te]),('Spatial block holdout',btr,bte,a,y_a[bte]),('Held-out section 151674',idx,np
      .arange(len(y_b)),b,y_b)]
results=[];preds={};train_sizes=[]
for scenario,itr,ite,test_section,truth in scenarios:
    projector=GeneProjector(a['genes']).fit(a['L'][itr]);ztr=projector.transform(a['L'][itr]);zte=projector.transform(test_section[
      'L'][ite])
    for name,model in new_models().items():
        model.fit(ztr,y_a[itr]);p=model.predict(zte);pr=model.predict_proba(zte)
        row={'scenario':scenario,'model':name,'n_train':len(itr),'n_test':len(ite),**metrics(truth,p,pr)};results.append(row)
        print('MODEL',row,flush=True)
        preds[(scenario,name)]=(truth,p,pr)
        if scenario.startswith('Held-out'):
            if name=='Logistic':final_lr=model;final_projector=projector;final_ztr=ztr;final_zte=zte
```

```
            pd.DataFrame({'barcode':test_section['obs'].index[ite],'true':truth,'pred':p,**{f'p_{l}':pr[:,i] for i,l in enumerate(
      LAYERS)}}).to_csv(DER/f'151674_predictions_{name}.csv',index=False)
    pd.DataFrame({'barcode':test_section['obs'].index[ite],'role':'test'}).to_csv(DER/f'split_{scenario.split()[0].lower()}_test.
      csv',index=False)
```

A.6 组织图像特征与配对空间块比较

以下三段直接摘自本次运行的 `src/extended_analysis.py`。图像读取依赖 Pillow；`a,b` 为开发和留出切片的对象，`za,zb` 为仅在开发片拟合的表达主成分。配对重采样让两组预测使用同一批块索引，避免把两个独立区间简单相减。

```
def image_features(sample,obs):
    """Simple colour/texture descriptors, not nuclei counts or stain deconvolution."""
    img=np.asarray(Image.open(ROOT/f'data/raw/{sample}/tissue_hires_image.png').convert('RGB'))/255.
    scale=json.loads((ROOT/f'data/raw/{sample}/scalefactors_json.json').read_text())
    # Same physical capture footprint in each sample; square window, no fake resolution.
    radius=max(2,int(round(scale['spot_diameter_fullres']*scale['tissue_hires_scalef']/2)))
    rows=[]
    for x,y in obs[['x','y']].to_numpy():
        x,y=int(round(x)),int(round(y));p=img[max(0,y-radius):min(img.shape[0],y+radius+1),max(0,x-radius):min(img.shape[1],x+
      radius+1)]
        v=p.reshape(-1,3);gray=p@np.array([.299,.587,.114]);dx=np.diff(gray,axis=1);dy=np.diff(gray,axis=0)
        rows.append([*v.mean(0),*v.std(0),float((gray<.65).mean()),float((np.mean(dx**2)+np.mean(dy**2))/2)])
    return pd.DataFrame(rows,index=obs.index,columns=IMAGE_FEATURES),radius

    # Image-only and a fixed concatenation; no coordinate, label or test-fitted transform.
    scaler=StandardScaler().fit(a['image_features']);ha=scaler.transform(a['image_features']);hb=scaler.transform(b['image_features
      '])
    for name,xtr,xte in [('Image only',ha,hb),('Expression + image',np.c_[za,ha],np.c_[zb,hb])]:
        model=LogisticRegression(C=1,solver='lbfgs',max_iter=2000,class_weight='balanced',random_state=SEED).fit(xtr,a['y'])
        prob=model.predict_proba(xte);pred=prob.argmax(1);models[name]=(pred,prob)
        pd.DataFrame({'barcode':b['obs'].index,'true':y,'pred':pred,**{f'p_{l}':prob[:,k] for k,l in enumerate(LAYERS)}}).to_csv(D/
      f'{name.replace(" ","_").replace("+","plus")}_predictions.csv',index=False)

def bootstrap_paired(y,p0,p1,groups,rng,reps=500):
    unique=np.unique(groups);index=[np.flatnonzero(groups==g) for g in unique];values=[]
    for _ in range(reps):
        ix=np.concatenate([index[i] for i in rng.integers(0,len(index),len(index))])
        values.append(f1_score(y[ix],p1[ix],labels=np.arange(7),average='macro',zero_division=0)-f1_score(y[ix],p0[ix],labels=np.
      arange(7),average='macro',zero_division=0))
    return np.asarray(values)
```

B 数据与文献核验清单

原始计数矩阵、组织图和缩放参数分别按样本编号保存。数据清单记录 12 个文件的来源与校验值；每次分析检查基因 ID 一致、条码唯一、标签一致、UMI 总和一致、图像坐标换算一致。预测表按条码保存真实类别、预测类别和七类概率，可独立重算指标。

全文 35 篇文献的题名、作者、年份、期刊、卷期、页码或文章号及 DOI 均根据 Crossref 注册记录核对；原始 JSON 与审核表随项目保存。综述涉及的方法与本次实际实现的方法分别说明。